1.知识获取的过程流程图:

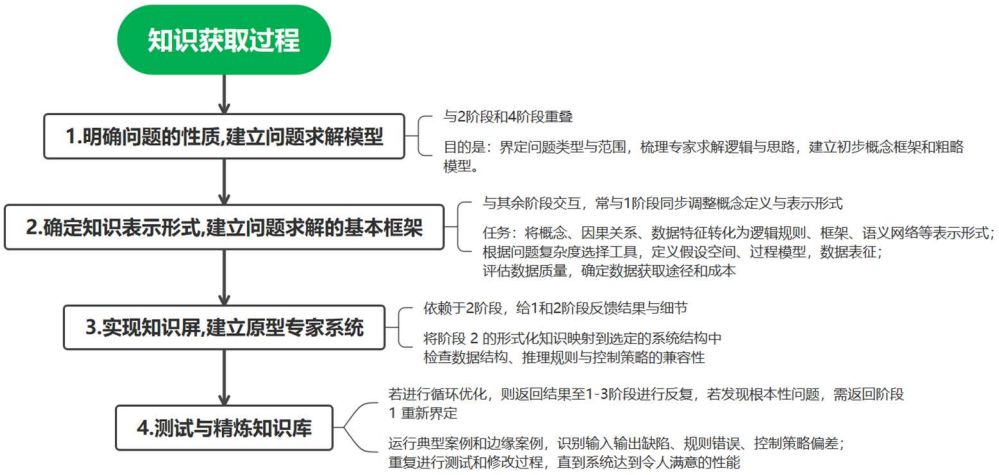

2. 数据挖掘与机器学习的关系和区别:
二者均为人工智能领域的核心技术，既紧密关联又各有侧重，共同推动从数据到知识的转化。数据挖掘是从海量数据中挖掘隐藏的、有价值的模式或规则的过程，涉及数据清理、集成、变换、模式评估等步骤，从一开始就是面向程序的；机器学习则是一种研究学习的理论，其通过算法让计算机从数据中自动学习规律，改进性能的过程，核心是构建模型从输入到输出的映射。数据挖掘着重于发现数据中的关联、分、预测等知识，而机器学习则通过训练数据优化模型参数，实现分类、回归、聚类等任务。
因此，数据挖掘依赖于机器学习算法来进行模式识别，而机器学习模型需要数据挖掘预处理后的数据作为输入。数据挖掘侧重“发现知识”，机器学习侧重“模型优化”，二者目标互补。同时二者区别显著。
数据挖掘的核心目标是：从数据中提取可解释的模式、规则，支持决策，而机器学习的核心目标为：构建模型实现预测或分类，优化系统性能；
数据挖掘的处理对象是结构化或半结构化或非结构化的数据，而机器学习则以结构化数据为主，同时这些结构化数据还需预处理为模型可接受的格式；
数据挖掘通过包括数据库技术、统计学、可视化等的多学科融合来发展，侧重于算法工程化，依赖领域知识进行模式评估，而机器学习聚焦于神经网络、遗传算法等算法理论，强调模型泛化能力，依赖数据驱动的模型调优；

3. Web 挖掘与文本挖掘的关系和区别
Web 挖掘是从 Web 数据中发现潜在模式的过程，涵盖内容、结构、用户行为三类数据，而文本挖掘是从非结构化文本数据中提取有价值知识的过程，涉及分类、聚类、情感分析等技术。
文本挖掘是 Web 内容挖掘的核心技术之一，而 Web 内容挖掘是 Web 挖掘的子集；二者均使用自然语言处理（NLP）、机器学习、统计分析等技术。这是文本挖掘和 Web 挖掘的共同点。
但 Web 挖掘的处理对象是多模态数据，如文本、图像、链接、日志等，侧重于 Web 特有的结构和行为数据，而文本挖掘则处理纯文本数据，重点关注语义和文本模式；
Web 挖掘的技术重点是结构分析和用户行为建模，文本挖掘则为语义抽取和文本分/聚类；

Web 挖掘的应用场景主要是搜索引擎优化，电商用户行为分析，网站结构优化等任务，而文本挖掘则主要处理专利分析、舆情监控等事务。

4. gSpan 算法的过程和主要特点

算法 gSpan 是基于深度优先搜索(DFS)及最右路径扩展技术生成频繁子图，以达到减少冗余候选子图的产生的目的。同时，gSpan 通过对访问过的顶点集合反复扩展，可以建立一个完全的深度优先搜索树。另外， gSpan 扩展时只对最小的 DFS 编码进行最右扩展，因面可以有效地减少产生复制图的数量。

其执行流程分为五步：

1.预处理：对每个图中的节点和边进行标号（如属性邻接图中的面和边属性），构建图的初始表示；为每个图生成最小 DFS 编码，唯一标识图结构，便于后续比较和扩展。

2.频繁 1-子图生成：提取所有单个节点或单边作为初始候选子图，统计支持度（出现次数），筛选出频繁 1-子图。

3.模式增长：扩展子图：对每个频繁 k-子图，通过最右路径扩展添加新边，生成 k+1-子图：选择子图的最右路径（DFS 遍历中的最后一条边），在其末端节点添加新边，确保扩展方向唯一，避免重复生成同构子图；对新生成的子图重新编码，检查是否已存在于候选集合中，避免冗余。

4.支持度计算与剪枝：遍历图数据集，统计每个候选子图的支持度，过滤低于阈值的子图；利用反单调性（若父模式非频繁，则子模式必不频繁）剪枝，减少搜索空间。

5.终止：当无法生成更高阶的频繁子图或所有候选子图均被处理时，算法终止，输出所有频繁子图。

其主要特点有四个：

1.高效性

通过 DFS 编码和最右路径扩展，确保每个子图仅生成一次，避免同构子图的重复计算，较传统 Apriori 类算法效率提升显著。

2.完备性

能够挖掘所有频繁连通子图，支持带属性的图数据，适用于复杂图结构。

3.灵活性

可调整支持度阈值和编码规则，适应不同领域需求。

4.局限性

对大规模图数据集内存消耗较大，需优化编码存储方式；在非连通图挖掘中效率下。

5. 图挖掘的特点、过程及应用领域

5.1.图挖掘的核心特点：

数据结构复杂性：处理节点-边的网状关系，而非传统的表格数据，需捕捉节点属性、边属性及全局结构特征。

模式多样性：挖掘对象包括频繁子、图聚类、图分类等，覆盖微观到宏观的多层模式。

领域依赖性：不同领域图数据差异显著，需定制化算法。

计算挑战性：子图同构检测、大规模图存储与计算对算法效率和分布式技术提出高要求。

5.2. 核心过程

1.图数据预处理：将现实对象抽象为图，定义节点和边的属性；处理缺失边和节点、消除噪声，构建高质量图数据集。

2.模式发现：使用 gSpan、AGM 等算法发现高频出现的子结构；将相似图或节点分组；基于

图特征训练分类器，区分不同类型的图。
3.模式分析与应用：通过图可视化工具展示模式，辅助领域专家理解。
5.3.应用领域
1.社交网络分析
挖掘用户关注关系图中的密集子图，识别兴趣社群，优化内容推荐；通过中心性分析识别关键节，设计病毒式营销路径。
2.生物信息学
挖掘频繁子图识别功能模块，揭示疾病相关的分子机制；通过图聚类分析代谢通路的相似性，辅助新药靶点筛选。
3.Web 与搜索引擎
利用 PageRank 算法挖掘网页超链接结构，评估网页权威性，优化搜索结果排序；通过日志生成的会话图，识别高频访问路径，改进网站导航设计。
4.制造业与软件工程
基于属性邻接图挖掘频繁子图，自动识别加工特征，助力 CAD/CAM 集成；分析程序依赖图中的异常子图，定位代码缺陷，提升调试效率。