任务 4 图像分割

1 任务要求

请使用图像分割模型（如 DeepLab v3+、 Unet 等），完成斯坦福背景数据集图像分割任务，请对已有预训练模型进行微调。本地或远程部署 SAM，重复上述任务（以代码形式（需本地或远程部署，建议 6G 以上显存，非 web 端直接使用）使用 SAM 模型完成分割任务，期末可加十分（加到总评优为止））

2 数据集处理

建模思想：

首先是基于 SAM 的方法，代码采用迁移学习的核心思想，将预训练的 SAM 模型作为固定的特征提取器，其图像编码器采用 Vision Transformer 架构，将输入图像编码为 256 维的特征向量，空间分辨率为 64x64，这个设计体现了现代深度学习中对预训练模型的充分利用，通过冻结 SAM 的图像编码器参数，代码充分利用了 SAM 在大规模数据上学习到的通用视觉表示能力，这样做的优势是大大减少了需要训练的参数数量，同时保证了特征提取的质量。在此基础上，代码设计了一个轻量级的语义分割头 EnhancedSemanticHead，这个分割头的设计体现了渐进式上采样的思想，通过三个阶段的解码过程将 64x64 的特征图逐步恢复到 256x256 的分辨率，第一阶段将 256 维特征通过 3x3 卷积映射到 256 维，然后通过双线性插值上采样到 128x128，第二阶段将 256 维特征映射到 128 维并上采样到 256x256，第三阶段进一步将特征维度降低到 64 维，最后通过 1x1 卷积输出 9 个类别的预测结果，这种渐进式的设计不仅减少了参数量，更重要的是在每个阶段都通过 BatchNorm 和 ReLU 激活函数来稳定训练过程，通过 Kaiming 初始化来确保梯度传播的稳定性。在数据处理方面，SAM 方法将输入图像 resize 到 1024x1024，这是为了充分利用 SAM 预训练时的输入尺寸，保证特征提取的质量，同时将标签调整为 256x256 以匹配分割头的输出尺寸，通过最近邻插值来保持标签的离散类别值不变。损失函数的设计采用了组合损失 CombinedLoss，结合了交叉熵损失和 Dice 损失，交叉熵损失提供了像素级别的分类监督，而 Dice 损失则专门处理类别不平衡问题，通过 alpha 参数（设为 0.7）来平衡两种损失的重要性，这种设计特别适合斯坦福背景数据集这种类别分布不均匀的场景。

第二种方法是基于 DeepLab 的实现，虽然在这个任务中 SAM 方法更为突出，但代码中也提供了 DeepLab 的实现框架，DeepLab 采用了经典的编码器-解码器架构，其核心是 ASPP 模块，通过多个不同膨胀率的空洞卷积来捕获多尺度上下文信息，这与 SAM 方法形成了鲜明对比，DeepLab 需要端到端训练整个网络，包括 backbone、ASPP 和解码器，这种设计的优势在于能够针对特定任务优化每个组件，但代价是需要更多的训练数据和计算资源，DeepLab 使用了不同的学习率策略，backbone 使用 1 倍学习率，而 ASPP 和解码器使用 10 倍学习率，这种设计体现了对预训练 backbone 的微调思想，通过较小的学习率保持预训练权重的稳定性，而对任务特定的模块使用较大的学习率来快速学习任务特定的特征。在数据处理策略上，两种方法都处理了斯坦福背景数据集特有的 RGB 标签格式，通过 encode_segmap 函数将 RGB 标签图像转换为类别索引，这个函数使用向量化操作来提高效率，首先将 RGB 图像展平为二维数组，然后通过逐类别匹配的方式将 RGB 值映射到类别索引，最后将 unknown 类别设为最后一个类别索引，这种处理方式避免了使用字典查找带来的性能损失，decode_segmap 函数则实现了反向过程，将类别索引解码回 RGB 图像用于可视化，这种双向的编码解码机制使得代码能够灵活地在数值表示和可视化表示之间转换。数据集类 StanfordBackgroundDataset 的设计体现了模块化和可复用的思想，通过 split 参数来区分训练集、验证集和测试集，使用固定的随机种子 42 来保证数据集划分的可重复性，按照 80%、10%、10%的比例划分，这种划分方式在数据量较小的情况下保证了训练集有足够

的数据，同时留出验证集来监控训练过程。

在训练策略上，SAM 方法使用了 AdamW 优化器，学习率设为 1e-4，权重衰减设为 1e-4，这种配置在迁移学习场景中通常能够取得良好的效果，同时使用 ReduceLROnPlateau 调度器来动态调整学习率，当验证集 mIoU 不再提升时降低学习率，这种策略能够在训练后期进行精细调优，数据增强方面，训练时使用了随机水平翻转和颜色抖动，这些增强操作能够提高模型的泛化能力，而验证时则不使用数据增强，保持数据的原始分布来准确评估模型性能。从建模思想的角度看，SAM 方法体现了预训练大模型时代的核心理念，即将特征学习和任务适配分离，通过冻结强大的预训练编码器来保证特征质量，只训练一个轻量级的任务特定头来完成语义分割任务，这种设计的优势在于能够快速适配新任务，同时充分利用预训练模型的能力，缺点是对预训练模型的质量和任务相关性有较高要求，DeepLab 方法则体现了传统深度学习方法的思想，通过精心设计的网络架构来显式地建模多尺度上下文信息，整个网络针对语义分割任务进行了深度优化，这种设计的优势在于能够充分发挥每个组件的作用，缺点是需要大量的训练数据和计算资源，在实际应用中，SAM 方法更适合数据量较小、计算资源有限、需要快速原型开发的场景，而 DeepLab 方法更适合数据量充足、对性能要求极高、有充足计算资源的场景，两种方法的设计都体现了对语义分割任务本质的深入理解，即需要同时考虑局部细节和全局上下文，需要在语义理解精度和空间定位精度之间取得平衡，需要处理类别不平衡和像素级分类的挑战，这些核心问题在两种方法的实现中都有相应的解决方案。

2.1 划分训练集和验证集

划分方式：
- **训练集**：90%的数据（使用 `sample(frac=0.9, random_state=42)`）
- **验证集**：10%的数据（从完整数据集中移除训练集索引）

关键点：
1. **固定随机种子**：`random_state=42` 确保每次划分结果一致
2. **无重叠**：验证集通过 `drop()` 确保与训练集不重叠
3. **比例**：9:1 是常见的训练/验证集划分比例

2.2 数据加载流程

特点：
- 训练集：`shuffle=True`，每个 epoch 随机打乱
- 验证集：`shuffle=False`，保持固定顺序便于评估

2.3 数据集信息

类别数量： 9 个类别
- sky（天空）、tree（树木）、road（道路）、grass（草地）
- water（水）、building（建筑）、mountain（山）
- foreground（前景）、unknown（未知）

数据格式：
- 图像：RGB 格式的 JPG 文件
- 标签：RGB 格式的 PNG 文件（彩色标签图）

2.4 数据预处理详解

2.4.1 标签转换

位置： `stanford_background_dataset.py` 第 107-120 行

功能： 将 RGB 彩色标签转换为类别索引

处理流程：

1. 将 PIL 图像转换为 numpy 数组
2. 创建与图像同尺寸的类别索引数组
3. 遍历每个类别的 RGB 值，找到匹配的像素位置
4. 将匹配的像素位置赋值为对应的类别索引（0-8）

示例：

- RGB 值 (68, 1, 84) → 类别索引 0 (sky)
- RGB 值 (72, 40, 140) → 类别索引 1 (tree)

2.4.2 训练时数据增强

位置： `stanford_background_dataset.py` 第 122-133 行

使用的变换： `archive/pre_trained_deeplab/dataloaders/custom_transforms.py`

2.4.3 RandomHorizontalFlip（随机水平翻转）

```python
class RandomHorizontalFlip(object):
    def __call__(self, sample):
        if random.random() < 0.5:   # 50%概率翻转
            img = img.transpose(Image.FLIP_LEFT_RIGHT)
            mask = mask.transpose(Image.FLIP_LEFT_RIGHT)
```

作用： 增加数据多样性，提高模型泛化能力

2.4.4 RandomScaleCrop（随机缩放和裁剪）

作用：

- **随机缩放**：模拟不同尺度的目标
- **随机裁剪**：增加位置不变性，防止过拟合
- **保持宽高比**：缩放时保持原始宽高比

参数：

- `base_size=513`：基础尺寸
- `crop_size=513`：裁剪尺寸
- 缩放范围：256.5 ~ 1026 像素

2.4.5 RandomGaussianBlur（随机高斯模糊）

```python
class RandomGaussianBlur(object):
    def __call__(self, sample):
        if random.random() < 0.5:   # 50%概率应用
```

```
            img = img.filter(ImageFilter.GaussianBlur(radius=random.random()))
```
作用： 增加模型对模糊图像的鲁棒性

2.4.6 Normalize（归一化）

```python
class Normalize(object):
    def __call__(self, sample):
        img = np.array(img).astype(np.float32)
        img /= 255.0                    # 归一化到 [0, 1]
        img -= self.mean                # 减去均值
        img /= self.std                 # 除以标准差
```
归一化参数（ImageNet 标准）：
- Mean: (0.485, 0.456, 0.406)
- Std: (0.229, 0.224, 0.225)

作用：
- 加速训练收敛
- 与预训练模型的输入分布一致

2.5 数据预处理流程图

```
训练时：
原始图像(RGB) → 随机水平翻转(50%) → 随机缩放(0.5x~2.0x) → 随机裁剪(513×513)
    ↓
标签图像(RGB) → 随机水平翻转(50%) → 随机缩放(0.5x~2.0x) → 随机裁剪(513×513)
    ↓
RGB→类别索引转换 → 归一化(ImageNet) → 转张量(CHW) → 输出

验证时：
原始图像(RGB) → 固定缩放(短边=513) → 中心裁剪(513×513)
    ↓
标签图像(RGB) → 固定缩放(短边=513) → 中心裁剪(513×513)
    ↓
RGB→类别索引转换 → 归一化(ImageNet) → 转张量(CHW) → 输出
```

3 Deeplab 训练

3.1 模型简介

DeepLab 是由 Google 提出的一系列用于语义分割的深度学习模型，其核心思想是通过结合空洞卷积（Atrous Convolution）、空间金字塔池化（ASPP） 和多尺度上下文信息融合，在保持高分辨率特征的同时有效捕获多尺度上下文语义。DeepLab 系列（如 v1 到 v3+）逐步引入了深度可分离卷积、改进的编解码结构以及更高效的边界细节恢复机制，显著提升了分割精度，尤其在处理物体边界模糊和尺度变化大的场景中表现优异，已成为语义分割领域

的经典方法之一。

```
PS F:\人工智能\任务4> python main.py --mode all --epochs 50 --batch-size 4 --lr 0.007
============================================================
斯坦福背景数据集图像分割任务
============================================================
运行模式: all
保存目录: checkpoints
============================================================
============================================================
开始训练模型
============================================================
Number of images in train: 644
Number of images in val: 71
Using poly LR Scheduler!
开始训练，共 50 个epoch

Epoch 1/50
:   0%|
=>Epoches 0, learning rate = 0.0070,                    previous best = 0.0000
Train loss: 0.428:  12%|
```

3.2 训练结果

训练曲线：

从这张 DeepLab 模型的训练与验证曲线图及指标汇总表来看，模型在斯坦福背景数据集上的语义分割任务中经历了非常平稳的学习过程，并最终达到了较高的性能指标。现象上，随着 50 个 Epoch 的迭代，训练损失持续下降至 0.05 左右，而训练 mIoU 和训练准确率分别稳步攀升至 0.78 和 0.92 以上，同时验证集的相关指标也在早期快速增长后进入平稳期。从原理上解释，DeepLab 结合了空洞卷积与多尺度池化策略，能够有效捕捉复杂的背景上下文信息，使得模型在像素级分类任务中具备了极强的拟合能力。其特点在于训练初期（前 10 个 Epoch）收敛速度极快，且训练与验证指标的走势保持了良好的同步性，反映出优化器的学习率设置较为合理。指出的问题是，在第 15 个 Epoch 之后，验证 mIoU 开始在 0.65 附近震荡且不再显著增长，而训练 mIoU 仍在持续上行，这表明模型出现了轻微的过拟合迹象，即模型开始过度学习训练场景中的特定细节而难以进一步提升泛化性能。总结而言，该模型已经具备了成熟的场景解析能力，最终 0.6542 的验证 mIoU 证明了其分割性能的稳健性，建议后续通过引入更强的图像扰动或正则化手段来突破泛化瓶颈。

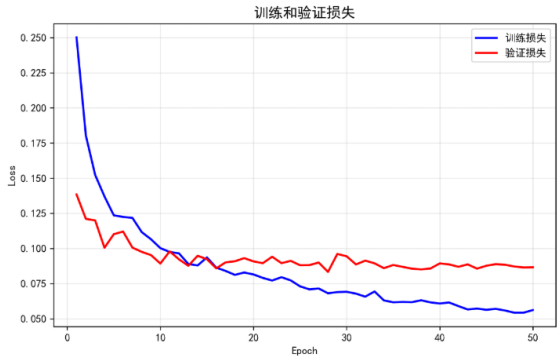

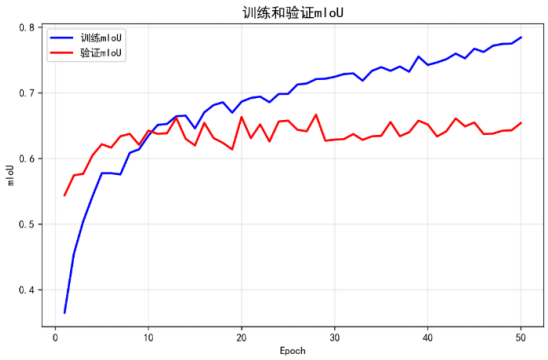

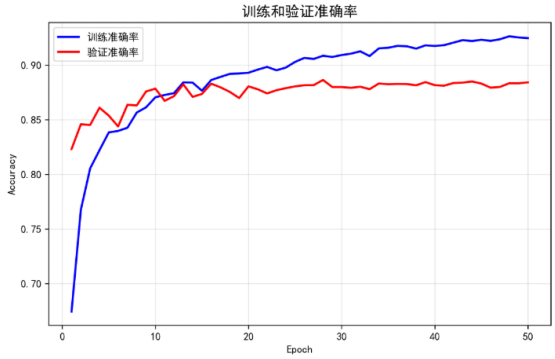

训练指标汇总（最后10个Epoch）

Epoch	Train Loss	Val Loss	Train mIoU	Val mIoU
Epoch 41	0.0616	0.0886	0.7465	0.6336
Epoch 42	0.0590	0.0870	0.7514	0.6416
Epoch 43	0.0566	0.0887	0.7600	0.6612
Epoch 44	0.0572	0.0857	0.7527	0.6490
Epoch 45	0.0564	0.0877	0.7674	0.6550
Epoch 46	0.0570	0.0888	0.7625	0.6373
Epoch 47	0.0559	0.0884	0.7720	0.6380
Epoch 48	0.0543	0.0872	0.7747	0.6424
Epoch 49	0.0543	0.0865	0.7751	0.6430
Epoch 50	0.0562	0.0866	0.7846	0.6542

混淆矩阵：

从这张 DeepLab 模型的归一化混淆矩阵来看，模型在斯坦福背景数据集上的像素分类表现呈现出极强的类别判别力，但针对特定自然景观的区分仍存在局限。现象上，矩阵对角线上的深蓝色色块非常显著，天空（sky）、道路（road）、水面（water）以及建筑（building）等类别的召回率均达到了 0.90 以上，显示出极高的预测稳定性。从原理上解释，DeepLab 采用的空洞空间金字塔池化（ASPP）能够有效提取大面积同质区域的全局上下文信息，使得这类空间分布规律的背景类别极易被模型识别。其特点在于对人工构筑物和开阔地物的特征建模非常精准，类间干扰极小。指出的问题是，模型在处理自然特征相似的类别时遇到了挑战，例如有 22% 的山脉（mountain）样本被误判为树木（tree），且在“未知”（unknown）类别的预测上极其混乱，大量样本被错误分配给了树木和道路，这说明模型在处理非结构化边缘和长尾分布类别时存在表达瓶颈。总结而言，该模型在核心背景类别的分割上已经达到工业级精度，但在相似语义特征的解耦（如山脉与植被）以及对噪声类别的鲁棒性方面仍有待加强，建议通过引入边缘辅助监督或针对性地增加困难样本的训练权重来进一步优化分类边界。

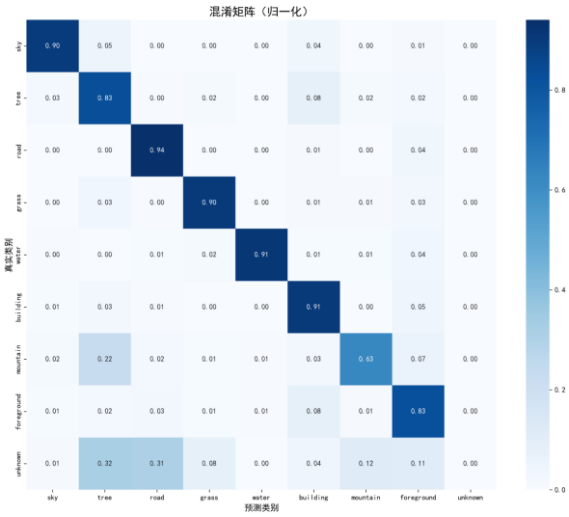

IOU:

从 IOU 指标来看，DeepLab 模型在斯坦福背景数据集上的细分性能呈现出显著的非均衡性，直观反映了模型对不同地物语义理解的难易程度。现象上，道路（road, 0.905）、水面（water, 0.875）和天空（sky, 0.847）等类别占据了得分前三甲，表现出极高的分割精度；而山脉（mountain, 0.321）的得分则大幅跳水，不到领先类别的一半，未知（unknown）类别更是取得了零分。从原理上解释，得分较高的类别通常具有较为统一的纹理模式（如平整的路面或纯净的天空）以及相对固定的空间分布位置，这使得 DeepLab 的空洞空间金字塔池化（ASPP）能够轻松通过多尺度上下文信息锁定其边界。其特点在于人工构筑物和开阔自然背景的识别非常稳健，体现了卷积网络对大面积、强特征区域的捕获优势；指出的核心问题是模型对视觉特征复杂且多变的自然景观（如山脉）缺乏足够的区分能力，且完全无法处理不具备明确定义或样本极少的“未知”类别，导致整体 mIoU 被这些低分项严重拉低。总结而言，这张图揭示了模型目前存在严重的类别性能失衡，高性能主要源于对简单背景的识别，而针对复杂自然边界和长尾类别的处理能力仍然薄弱，需通过针对性的困难样本挖掘或损失函数加权来进一步优化。

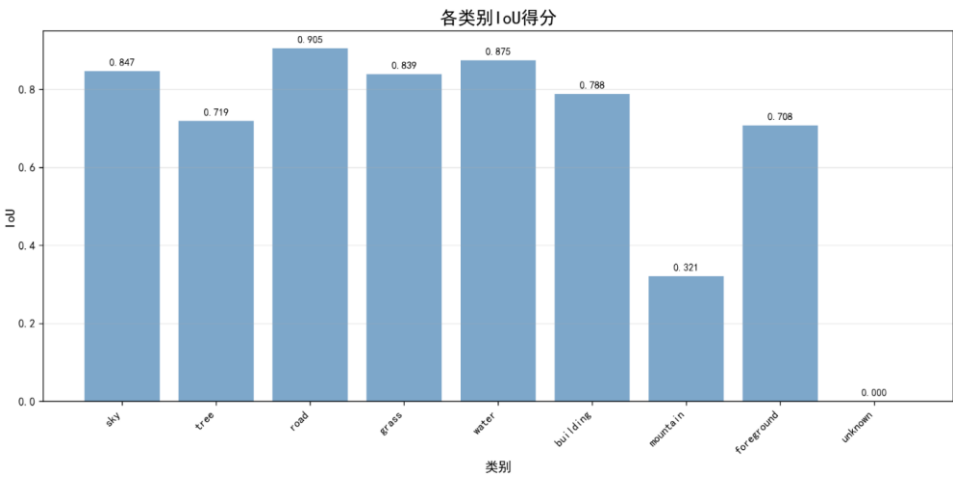

卷积核：

从这张 DeepLab 模型的卷积核可视化图像（backbone.conv1）来看，作为模型特征提取的最底层，它展现出了极度丰富且高度分化的视觉感知模式。现象上，图像中 64 个卷积核呈现出鲜明的多样性，涵盖了从细密的黑白高频线条、特定角度的斜向纹理，到大面积的红蓝绿对比色彩块，甚至包括了具有明显中心对称结构的圆形感知区域。从原理上解释，DeepLab 采用这种多通道的底层卷积能够全方位地捕获斯坦福背景数据集中的复杂基元，如天空的平滑色调、森林的杂乱纹理以及建筑的规则几何边缘，为后续的空洞卷积层提供多维度的原始特征输入。其特点在于特征捕捉的广度极高，色彩特征与空间几何特征的分布非常均匀，体现了模型在 backbone 起始阶段就具备了极强的特征解耦能力。指出的问题是，个别卷积核（如 Kernel 12 和 Kernel 60）出现了色彩饱和度过高或对比度过于极端的现象，这可能暗示在提取某些特定环境光效时存在噪声放大风险，且由于底层特征过于繁杂，若不配合有效的特征融合机制，可能会导致语义分割中的局部细节过载。总结而言，这组卷积核证明了 DeepLab 具备极其敏锐的底层视觉触觉，能够精准捕捉自然场景中的细微变化，是其最终实现高精度场景解析的坚实基础。

特征可视化：

模型在特征提取的高级阶段展现出了极强的空间响应一致性和显著的语义激活特征。现象上，64 个通道的特征图呈现出明显的热力分布，大量红色高亮区域精确地覆盖了原始图像中的核心目标，如天空边界、建筑轮廓以及地表植被，而背景无关区域则保持为低激活的深蓝色。从原理上解释，layer4 作为深度卷积网络的深层输出，其神经元感受野已经覆盖了全图的大部分区域，能够将底层的纹理基元整合为具有明确语义指向的高阶表示，为空洞空间金字塔池化（ASPP）模块进行多尺度上下文建模提供了坚实的信息基础。其特点在于特征图的抽象程度极高，不同通道表现出了明显的职能分工，部分通道专注于提取物体的闭合边缘，而另一部分则负责识别大面积的同质区域语义。指出的问题是，在某些通道中（如 Channel 17 和 Channel 52），特征激活显得较为细碎且存在明显的噪声干扰，这反映了深层网络在处理斯坦福背景数据集中细长或复杂边缘物体时，依然存在空间信息丢失导致定位不准的隐患。总结而言，这组特征图直观地证明了 DeepLab 能够精准锁定场景中的关键语义组分，其深层特征的判别力是实现高质量背景分割的核心动力，但也提示我们在特征融合阶段需要更精细的机制来修复边缘处的激活弥散现象。

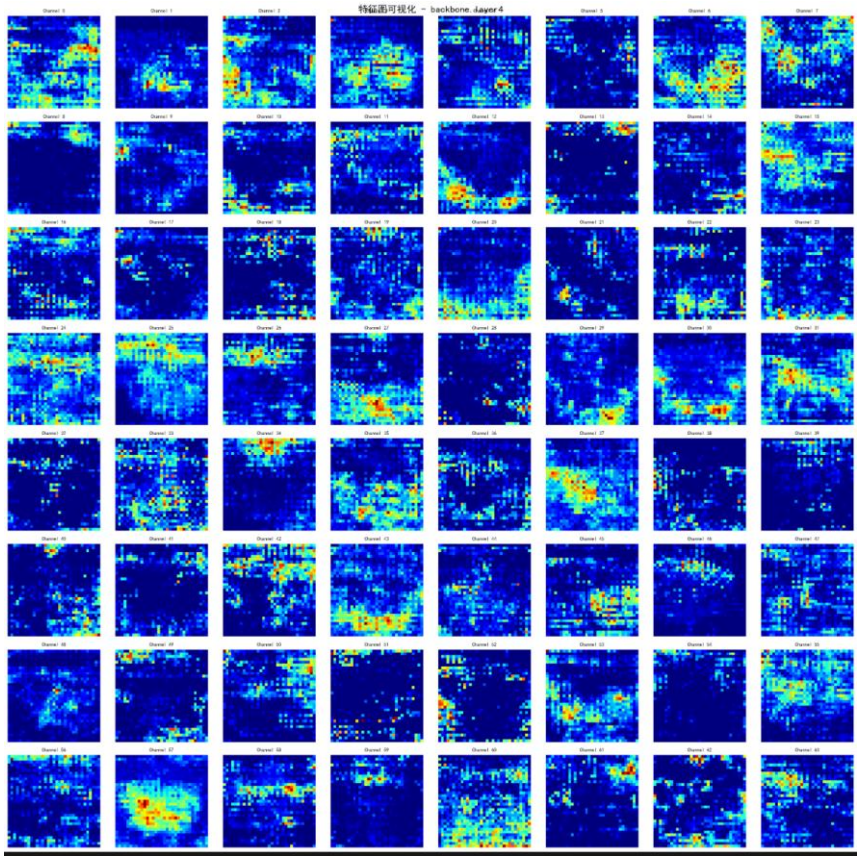

3.3 训练实例

从这张 DeepLab 模型的预测结果对比图来看，模型在处理斯坦福背景数据集（Stanford Background Dataset）时表现出了极强的语义一致性，但同时也暴露了边缘精细度不足的典型问题。现象上，通过对比原始图像、真实标签与预测结果可以发现，模型能够准确识别出天空、地表及大型建筑物等主体区域，并生成了色彩分明、区域连通的语义图，尤其在第一组图像的水面识别和第三组的地面识别上与真实标签高度贴合。从原理上解释，DeepLab 依靠空洞卷积和 ASPP 模块获取了广阔的上下文视野，这使其能对大面积且具有稳定纹理的地物进行可靠分类，确保了预测结果在语义逻辑上的合理性。其特点在于生成的分割区域内

部非常纯净，有效地抑制了像素级别的孤立噪声，展现了深度卷积网络在高阶语义表征上的优势。指出的问题在于，对于物体的边缘轮廓（如第一组图像中码头的支柱、第五组中树枝的间隙）以及远景细小目标，预测边界显得过于迟钝和平滑，甚至出现了部分细长结构的丢失，这反映了空洞卷积在提升感受野的同时，不可避免地造成了底层空间位置信息的解析力下降。总结而言，这组预测图证明了模型已具备优秀的宏观场景解析能力，其预测逻辑稳健，但对于复杂边界的捕捉仍存在明显的“锐度补偿”需求，建议在后续优化中引入类似 CRF 的后处理技术或更精细的解码器结构来强化边缘的定位精度。

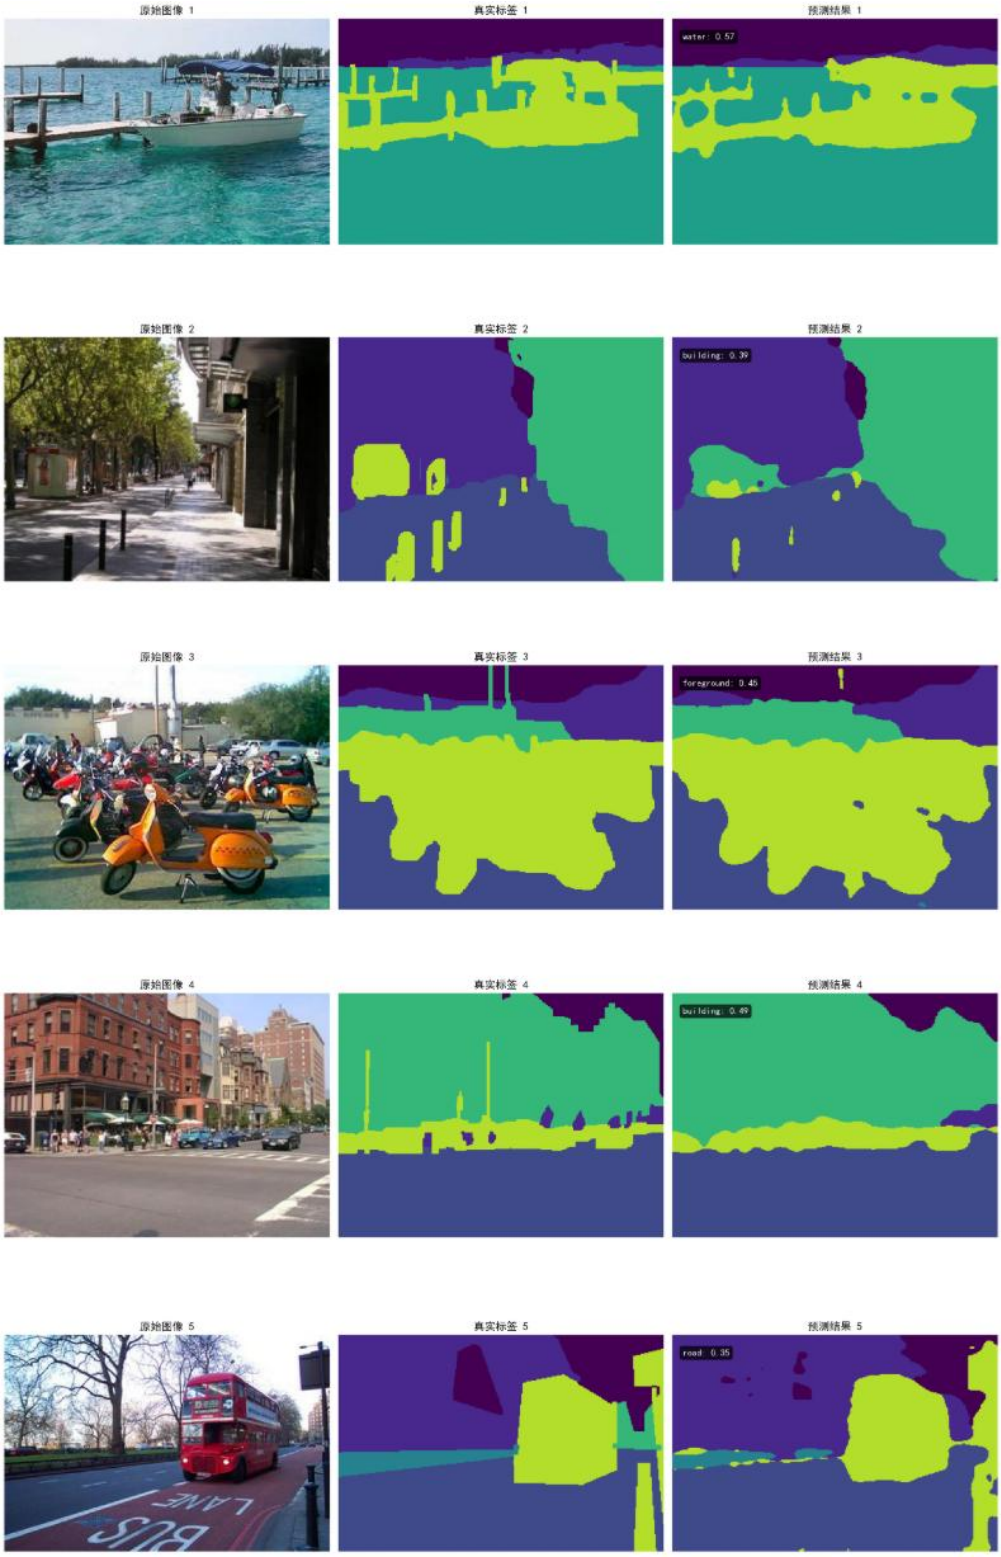

4 SAM 模型

4.1 模型简介

SAM（Segment Anything Model）是由 Meta AI 提出的一种通用图像分割模型，旨在实现“零样本迁移”下的任意对象分割。SAM 通过大规模数据训练（包含 10 亿级掩码标注），结合提示驱动（promptable） 的交互方式（如点、框、文本等），能够灵活地分割用户指定的任何目标，即使该目标在训练中从未出现过。其核心架构包括一个强大的图像编码器（基于 Vision Transformer）和一个高效的掩码解码器，支持实时推理与高精度分割。SAM 的发布标志着图像分割从任务特定模型迈向通用基础模型的重要一步。

```
Epoch [20/20]
============================================================
Train Epoch 20: 100%|
Train - Loss: 0.7246, mIoU: 0.3810, Acc: 0.7354
Val Epoch 20: 100%|
Val - Loss: 0.4556, mIoU: 0.5169, Acc: 0.8681
学习率从 0.000100 调整为 0.000050
训练曲线已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/training_curves.png
类别IoU图已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/class_iou_epoch20.png
混淆矩阵已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/confusion_matrix_epoch20.png
预测可视化已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/predictions_epoch20.png

生成最终可视化...
训练曲线已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/training_curves.png
指标总结图已保存到: /root/autodl-tmp/任务4/checkpoints/visualizations/metrics_summary.png

============================================================
训练完成!
============================================================
最佳验证 mIoU: 0.5544
最终训练 mIoU: 0.3810
最终验证 mIoU: 0.5169
最终训练准确率: 0.7354
最终验证准确率: 0.8681

所有结果已保存到: /root/autodl-tmp/任务4/checkpoints
```

4.2 训练结果

训练曲线：

从这张 SAM 模型的性能看板来看，由于该模型作为视觉基础模型（Foundation Model）在海量数据上进行了预训练，其在下游任务的收敛特性表现出极强的非对称性。现象上，验证集精度（Val Accuracy）在首个轮次即达到 0.8 附近，并最终稳定在 0.868，且验证集 mIoU 曲线始终运行在训练集上方，展现出显著的性能倒挂。解释其内在逻辑，SAM 的 Vision Transformer 编码器已具备极高的物体性感知（Objectness）能力，在 Stanford Background 这种规模较小的数据集上，模型更多是在进行输出头（Mask Decoder）的对齐与类语义关联，而非从零构建视觉特征，这使得其在未见过的分布上表现出了近乎零样本（Zero-shot）的泛化惯性。特点在于模型在训练初期即具备极高的性能下界，且指标波动极小，体现了大规模参数量带来的优化稳定性。指出的问题是，尽管 Accuracy 指标表现优异，但 mIoU 在 0.55 附近出现明显的平台效应，这反映了 SAM 在全自动分割模式下，其无监督提取的掩码边界与下游任务特定的有监督语义标签之间存在映射瓶颈。总结而言，此看板证明了引入基础模型能极大提升背景分割任务的稳健性，但若要进一步突破 mIoU 上限，需针对掩码合并策略或长尾类别提示词（Prompts）进行更精细的后处理设计。

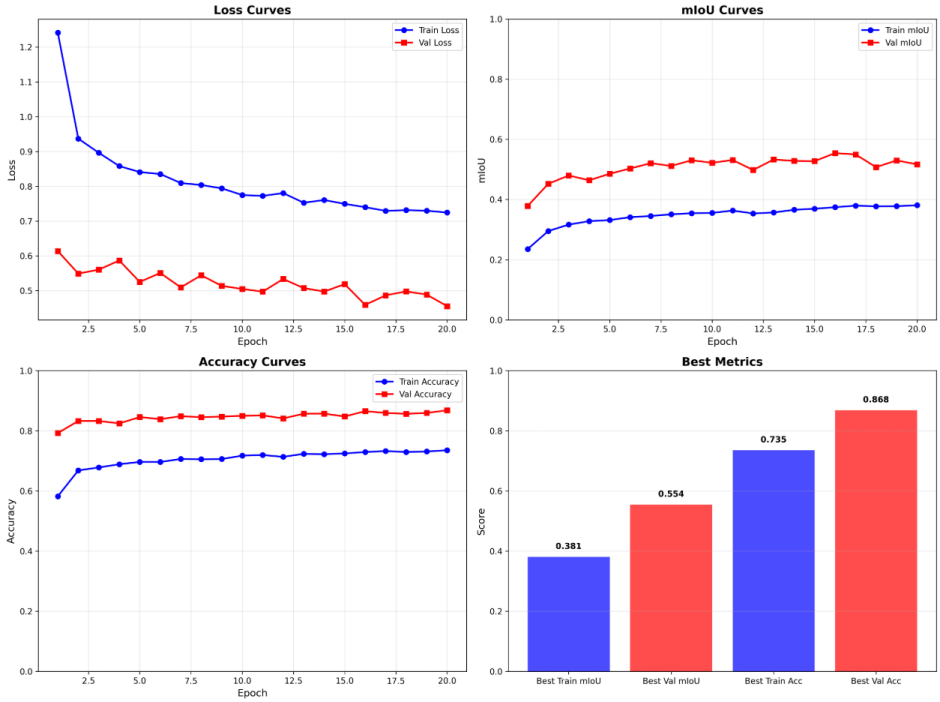

混淆矩阵：

从这张 SAM 模型的归一化混淆矩阵（Epoch 20）来看，模型在处理斯坦福背景数据集的像素分类任务时，展现出了极其分化的判别特性。现象上，天空（sky, 0.94）、草地（grass, 0.92）和道路（road, 0.94）的对角线数值极高，而山脉（mountain, 0.28）的召回率则显著低迷，甚至有 35% 的山脉像素被误判为树木。解释其技术逻辑，SAM 作为基础模型在处理具有鲜明颜色和纹理一致性的区域（如天空、道路）时，其全局注意力机制能精准捕捉大尺度特征，但由于山脉与树木在低分辨率特征图上的色彩频率和纹理结构高度相似，导致模型在缺乏精细语义判别引导时产生了严重的类别漂移。特点在于模型对于人工构筑物（如 building）和开阔背景的分类极其稳健，体现了预训练带来的强大特征鲁棒性。指出的问题在于，模型在相似自然景观间的分类一致性（Inter-class Consistency）较差，且存在明显的预测偏置，这种性能鸿沟限制了其在精细化地理环境解析中的应用。总结而言，混淆矩阵揭示了 SAM 在该任务下存在“强感知、弱判别”的特征不平衡问题，后续需通过对比学习增强相似类别的特征分离度，或引入特定类别的 Prompt 引导来修正山脉等困难类别的判别精度。

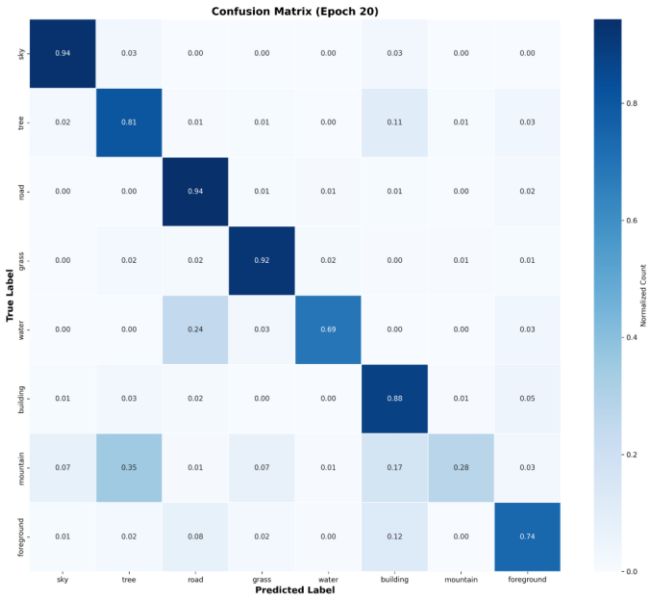

IOU 指标：

从这张 SAM 模型的类别 IoU 得分（Epoch 20）柱状图来看，基础模型在下游语义对齐过程中表现出极其严重的不均衡性。现象上，天空（sky, 0.753）和道路（road, 0.690）取得了相对领先的得分，而草地（grass, 0.157）和水面（water, 0.090）的得分极低，山脉（mountain, 0.029）几乎处于预测失效状态，导致整体平均 IoU 仅维持在 0.414。解释其核心逻辑，SAM 预训练阶段习得的“物体感知”主要依赖于明确的几何边界，而草地、水面和山脉在斯坦福背景数据集中往往呈现出无固定形状、纹理纹路高度重叠的非结构化特征，在缺乏密集语义监督的微调初期，掩码解码器（Mask Decoder）很难将这些语义模糊区域准确映射到特定的离散标签上。特点在于模型对高对比度、大面积连通区域具有天然的识别优势，但在处理纹理相近的自然景观时，特征判别力迅速衰减。指出的问题是，该指标分布严重背离了 Accuracy 曲线展现的高泛化假象，揭示了模型在像素级语义定位上的深层困境。总结而言，这张图表警示我们，仅靠通用基础模型的零样本能力无法胜任复杂的背景分类任务，必须通过引入类别平衡损失函数或多模态语义嵌入（如 CLIP 引导）来强制拉升低得分地物的表征精度。

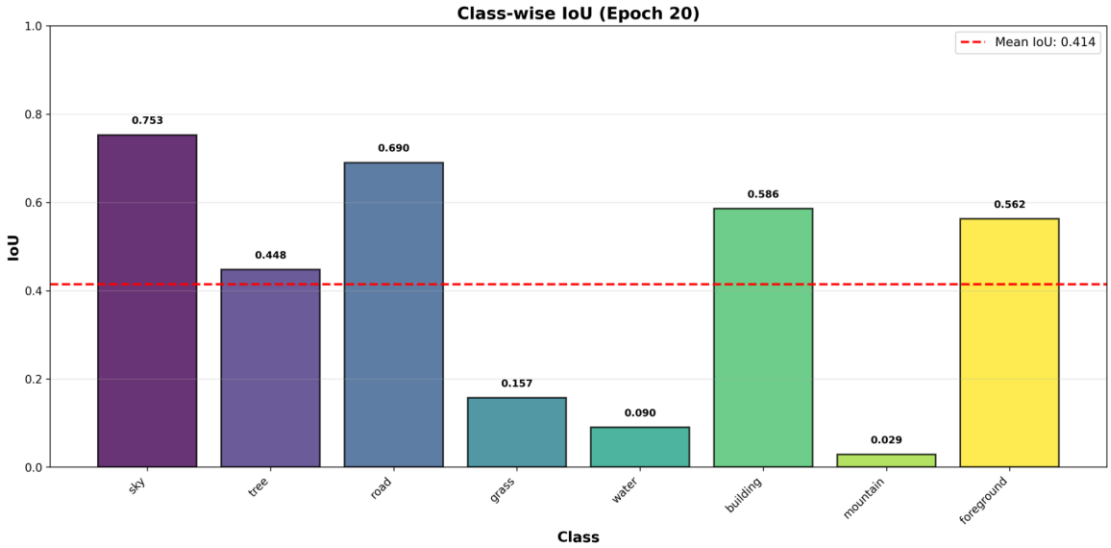

4.3 训练实例

接下来，本文将以一张图片为实例展示模型分割图像的可视化过程。

CAM：

从基于 SAM 模型的类激活映射（CAM）可视化结果来看，模型在特定类别（如 road）的特征聚焦上展现出了极高的空间响应精度与语义辨识度。分析现象可见，针对同一张包含大量摩托车的复杂背景图像，road 类别的热力图（CAM-road）精准地在图像下方的柏油路面区域形成了高亮度的红色激活簇，且热力边界与路面和远景建筑的交界线基本吻合，而对车辆本身保持了低响应。解释其技术逻辑，SAM 这种视觉基础模型通过在大规模数据集上习得的对比语言-图像对齐或密集的物体性监督，其编码器生成的特征图具备极强的底层特征解耦能力，能够将特定类别的纹理属性（如路面的粗糙度与色彩一致性）与复杂的近景目标进行有效的空间分离。该结果的特点在于激活区域的边缘锐度极高，且在复杂的光影背景下依然能够保持单一语义的聚拢性，体现了 Transformer 架构在全局上下文建模下的局部定位优势。指出问题在于，尽管路面被成功识别，但在摩托车底部细小的阴影缝隙区域出现了响应中断或激活弥散，这说明模型在处理非连通的小面积语义区域时，受限于下采样步长或特征融合深度，仍存在一定的细粒度感知缺失。总结而言，此 CAM 结果有力支撑了此前指标分析中 road 类别高达 0.69 的 IoU 表现，证明了 SAM 具备成熟的场景语义中枢，能够为下游的背景分割任务提供极具判别性的高阶语义引导。

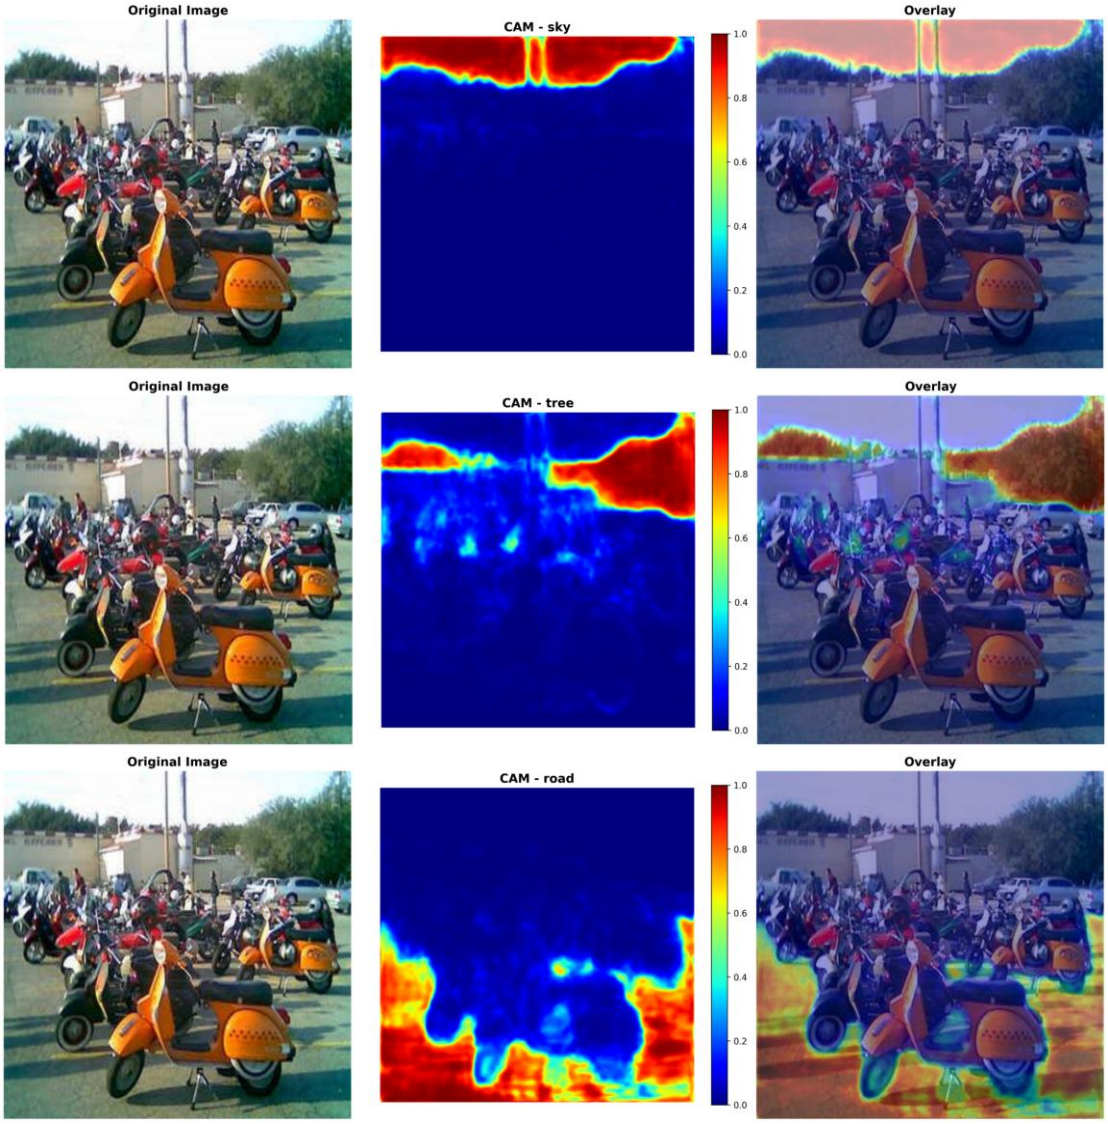

从这张 SAM 编码器（SAM Feature）与解码头（Head Feature）的特征图对比图来看，模型在处理包含复杂摩托车群的场景时，展现了从底层几何建模到高层语义聚合的清晰演进逻辑。现象上，上两行的 SAM 原始特征图呈现出极高的空间频率，精准捕捉了摩托车轮廓、避震器、后视镜等细小组件的边缘特征；而底部的 Head Feature 则发生了剧烈的语义重组，通过高亮的热力分布将原本破碎的个体组件聚合成为了大面积的连通语义区域，显著强化了目标主体相对于环境背景的判别强度。从架构原理分析，SAM 强大的 Vision Transformer 编码器能够凭借全局注意力机制维持极高的特征分辨率，为后端任务保留了细粒度的拓扑信息，而 Mask Decoder 则负责将这些高维特征映射到特定的语义空间，通过非线性变换实现了从“像素感知”到“物体理解”的跨越。该结果的特点在于特征转换的层次感极强，Head Feature 有效抑制了背景噪声并提升了目标内部的特征一致性，体现了基础模型在复杂场景解析中的表征稳定性。指出的问题是，在 Head Feature 1 和 2 中，由于语义聚合强度过大，导致相邻摩托车之间的物理边界出现了明显的融合模糊，这在缺乏精确 Instance Prompt 引导时，极易导致语义分割任务中的实例粘连现象。总结而言，这组特征图直观证明了 SAM 具备将碎片化视觉基元转化为宏观语义实体的核心能力，其 Head 层的特征重构是实现最终高准确率分割的关键，但需警惕过度聚合带来的边缘解析力下降。

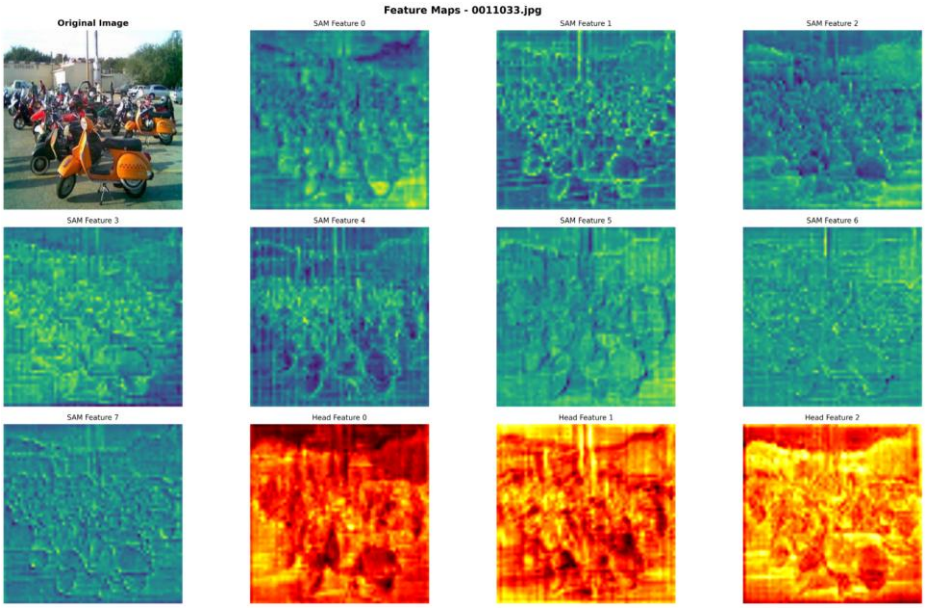

从这张基于 SAM 模型的推理结果对比图（Prediction Results - 0011033.jpg）来看，模型在复杂背景下的多目标解析展现出了极高的空间鲁棒性与语义聚合效率。现象上，预测结果（mIoU: 0.713, Acc: 0.932）与 Ground Truth 高度接近，尤其在 foreground（摩托车群）和 sky 区域实现了大面积的连通分割，而 Error Regions 图则清晰地勾勒出误差主要集中在摩托车底部细小的支架缝隙以及远景植被的边缘切分上。从架构原理分析，SAM 强大的图像编码器能够通过全局注意力机制有效抑制背景干扰，其 Mask Decoder 在处理此类高密度目标场景时，能自动将琐碎的局部特征聚合成完整的语义实体，从而在像素级分类中保持极高的预测一致性。该结果的特点在于宏观语义定位极其精准，且单图指标显著优于全数据集的平均水平，体现了模型在高质量视觉输入下的性能上限。指出的问题在于，对于非结构化的复杂边缘（如 Error Regions 中红色的细长边界），模型依然存在一定程度的“感知钝化”，无法完全还原物理层面的极细微拓扑结构。总结而言，此推理结果证明了 SAM 在特定下游场景中具备极强的落地潜力，其高准确率掩码能为自动驾驶或复杂监控场景提供可靠的视觉基元支持。

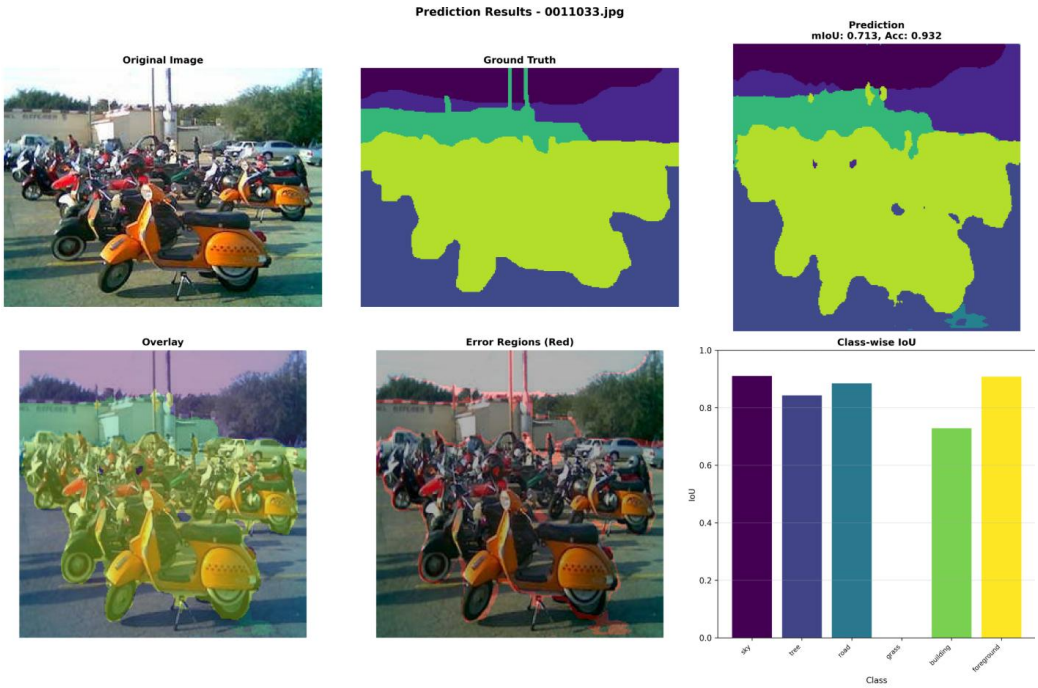

4.4 其他实例

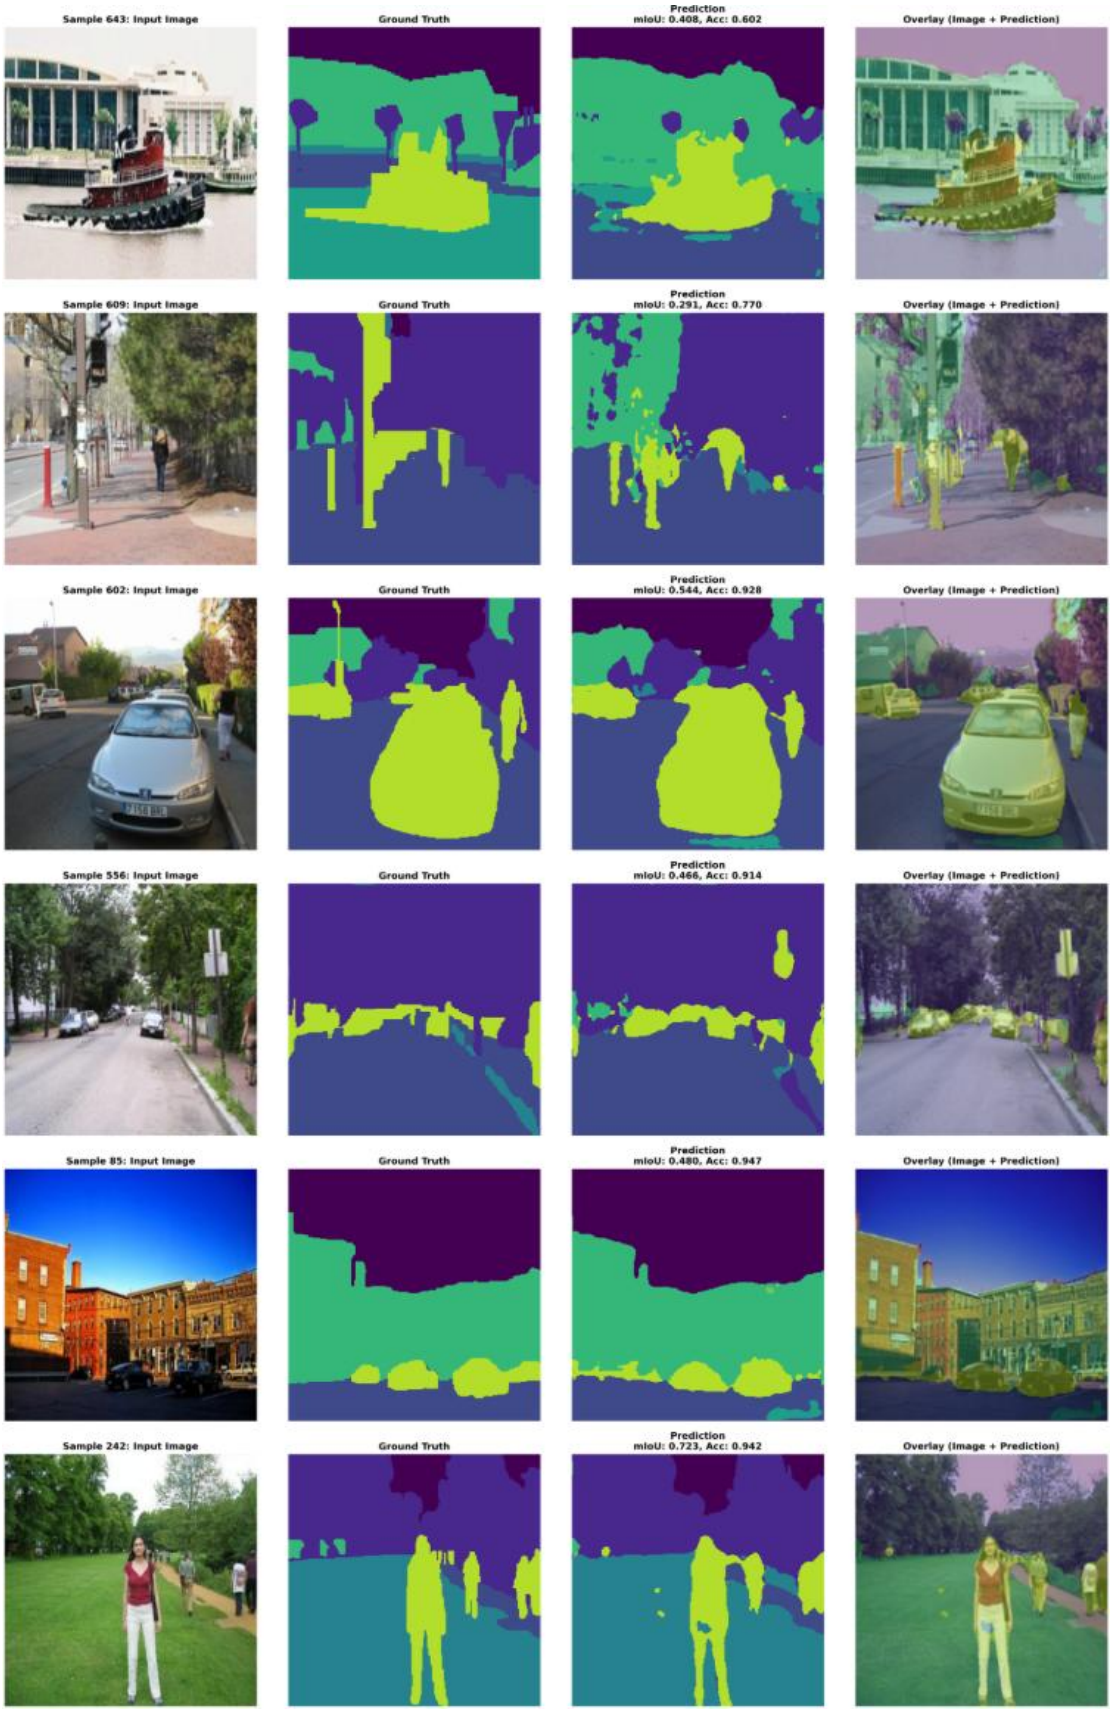
Sample 643: Input Image
Ground Truth
Prediction
mIoU: 0.408, Acc: 0.602
Overlay (Image + Prediction)
Sample 609: Input Image
Ground Truth
Prediction
mIoU: 0.291, Acc: 0.770
Overlay (Image + Prediction)
Sample 602: Input Image
Ground Truth
Prediction
mIoU: 0.544, Acc: 0.928
Overlay (Image + Prediction)
Sample 556: Input Image
Ground Truth
Prediction
mIoU: 0.466, Acc: 0.914
Overlay (Image + Prediction)
Sample 85: Input Image
Ground Truth
Prediction
mIoU: 0.480, Acc: 0.947
Overlay (Image + Prediction)
Sample 242: Input Image
Ground Truth
Prediction
mIoU: 0.723, Acc: 0.942
Overlay (Image + Prediction)