任务 5 手写文字和风格迁移

1 任务要求

（1）使用原始的 GAN 网络来生成手写数字

（2）使用 DCGAN、条件 GAN（cGAN）网络来生成手写数字

（3）图像风格迁移

2 代码框架

建模思想：

本项目的建模思想围绕生成对抗网络（GAN）和图像风格迁移两大核心技术展开，采用模块化设计理念，通过渐进式架构演进实现从基础到高级的生成式模型构建。整体框架以对抗训练为核心思想，通过生成器与判别器的动态博弈过程学习数据分布，其中原始 GAN 采用全连接层构建生成器和判别器网络，生成器将 100 维随机噪声向量通过多层全连接网络逐步映射到 784 维的图像空间，使用 LeakyReLU 激活函数增强梯度流动，最终通过 Tanh 激活将输出限制在[-1,1]范围内以匹配归一化的 MNIST 数据，判别器则采用相反的结构将图像展平后通过多层全连接网络压缩至单一概率值，使用 Sigmoid 激活输出真实概率，训练过程遵循交替优化策略，判别器同时学习区分真实图像和生成图像，生成器则试图欺骗判别器使其认为生成的图像是真实的，这种对抗机制促使生成器不断改进以生成更逼真的样本。DCGAN 在此基础上引入卷积神经网络架构以更好地处理图像的空间结构信息，生成器使用转置卷积层实现从低维噪声到高维图像的渐进式上采样过程，通过 BatchNorm 层稳定训练并加速收敛，判别器采用标准卷积层逐步下采样提取特征，这种架构设计充分利用了卷积操作对空间局部性的建模能力，相比全连接层显著减少了参数量同时提升了特征表示能力。条件 GAN 进一步扩展了模型的表达能力，通过引入类别嵌入机制将类别标签信息融入生成过程，生成器将类别标签通过嵌入层转换为高维向量后与噪声向量拼接作为输入，使得生成过程可以受到类别条件的显式控制，判别器同样接收类别信息并与图像特征融合进行判断，这种条件约束不仅提高了生成质量还实现了可控生成这一重要功能。

图像风格迁移任务则采用了完全不同的建模思路，基于预训练的 VGG19 深度卷积神经网络作为特征提取器，利用深度网络不同层次捕获不同抽象程度的视觉特征这一特性，通过多层特征匹配同时保持内容图像的结构信息和风格图像的纹理风格，内容损失通过计算生成图像与内容图像在高层特征层（relu4_1）的特征差异来衡量，风格损失则通过 Gram 矩阵捕捉特征图之间的统计相关性来表征纹理风格，Gram 矩阵的计算将特征图的空间信息抽象为通道间的相关关系，这种设计使得风格表示与图像内容解耦，通过加权组合内容损失和风格损失构建总损失函数，使用 LBFGS 优化算法迭代优化生成图像，使其在保持内容结构的同时逐渐获得风格图像的纹理特征。整个代码框架遵循统一的工程化设计模式，每个模型模块独立封装但遵循相似的结构，包含模型定义、训练循环、损失计算、结果保存和可视化分析等标准化流程，训练过程采用 Adam 优化器（风格迁移使用 LBFGS）配合学习率衰减策略，通过记录和可视化损失曲线、生成样本、网络结构等多维度信息辅助模型分析和调试，结果分析模块提供统计指标计算、对比分析和报告生成功能，使得整个实验过程具有完整的可追溯性和可复现性。

```
├── vanilla_gan.py        #  原始 GAN 实现
├── dcgan.py              # DCGAN 实现
├── cgan.py               #  条件 GAN 实现
├── style_transfer.py     #  图像风格迁移实现
```

```
├── main.py                  # 主运行脚本
├── compare_results.py   # 结果对比分析脚本
├── requirements.txt       # 依赖包列表
├── picture/                 # 图片文件夹
│    ├── house.jpg           # 内容图像
│    └── star.jpg            # 风格图像
└── results/                 # 结果输出目录（运行后生成）
```

超参数说明
GAN 模型超参数
- `BATCH_SIZE`: 批次大小（默认 64）
- `LATENT_DIM`: 噪声向量维度（默认 100）
- `LEARNING_RATE`: 学习率（默认 0.0002）
- `NUM_EPOCHS`: 训练轮数（默认 50）
- `SAVE_INTERVAL`: 保存间隔（默认每 5 个 epoch）

风格迁移超参数
- `num_iterations`: 迭代次数（默认 300）
- `content_weight`: 内容权重（默认 1）
- `style_weight`: 风格权重（默认 1000）
- `lr`: 学习率（默认 0.01）

3 原始的 GAN 网络来生成手写数字
3.1 模型介绍

生成对抗网络（GAN, Generative Adversarial Network）是由 Ian Goodfellow 等人于 2014 年提出的一种深度生成模型，其核心思想是通过两个神经网络的对抗博弈来学习真实数据的分布：生成器（Generator）试图从随机噪声中生成逼真的假样本，而判别器（Discriminator）则努力区分真实样本与生成样本。两者在训练过程中相互对抗、共同进化，最终达到纳什均衡，使得生成器能够输出高度逼真、难以被判别器识别的样本。GAN 在图像生成、风格迁移、超分辨率、数据增强等领域取得了突破性成果，成为生成式人工智能的重要基石之一。

3.2 模型训练
判别器网络结构:
```
==================================================
Discriminator(
  (model): Sequential(
    (0): Linear(in_features=784, out_features=1024, bias=True)
    (1): LeakyReLU(negative_slope=0.2)
    (2): Dropout(p=0.3, inplace=False)
    (3): Linear(in_features=1024, out_features=512, bias=True)
    (4): LeakyReLU(negative_slope=0.2)
    (5): Dropout(p=0.3, inplace=False)
```

```
    (6): Linear(in_features=512, out_features=256, bias=True)
    (7): LeakyReLU(negative_slope=0.2)
    (8): Dropout(p=0.3, inplace=False)
    (9): Linear(in_features=256, out_features=1, bias=True)
    (10): Sigmoid()
  )
)
```

参数统计:
总参数数量: 1,460,225
可训练参数: 1,460,225
生成器网络结构:

```
==================================================
Generator(
  (model): Sequential(
    (0): Linear(in_features=100, out_features=256, bias=True)
    (1): LeakyReLU(negative_slope=0.2)
    (2): Linear(in_features=256, out_features=512, bias=True)
    (3): LeakyReLU(negative_slope=0.2)
    (4): Linear(in_features=512, out_features=1024, bias=True)
    (5): LeakyReLU(negative_slope=0.2)
    (6): Linear(in_features=1024, out_features=784, bias=True)
    (7): Tanh()
  )
)
```

参数统计:
总参数数量: 1,486,352
可训练参数: 1,486,352

训练曲线:

从这张原始 GAN 模型生成器与判别器的损失变化趋势图来看，训练过程呈现出典型的生成对抗博弈初期剧烈波动后趋于平稳的特征。分析现象可见，生成器损失（Generator Loss）在起始阶段经历了一次陡峭的上升，随后转入持续的指数级下降并最终稳定在 1.0 附近，而判别器损失（Discriminator Loss）则在极低位起步后缓慢攀升至约 0.6 处。解释其内在逻辑，这种此消彼长的态势反映了生成器在对抗压力下不断提升造假能力，迫使原本占据绝对优势的判别器逐渐难以区分真实样本与生成样本，体现了二者在特征空间分布上的初步对齐。该结果的特点在于生成器损失曲线下降平滑且无明显的梯度消失现象，说明模型成功避开了训练初期的灾难性发散。指出的问题是，两条曲线在 20 个 Epoch 后几乎完全平行且不再交叉，这暗示模型可能陷入了某种局部的纳什均衡，生成能力进入了增长平台期，导致生成的手写数字可能依然存在一定的模糊感。总结而言，此损失看板证明了原始 GAN 框架在 MNIST 任务上的基本有效性，其稳定的收敛轨迹为生成质量的进一步提升打下了基础，但同时也预示了若不引入卷积结构，模型很难在特征细节上实现质的突破。

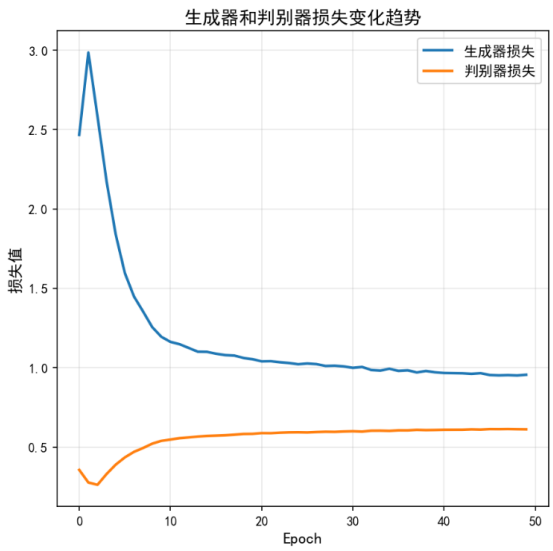

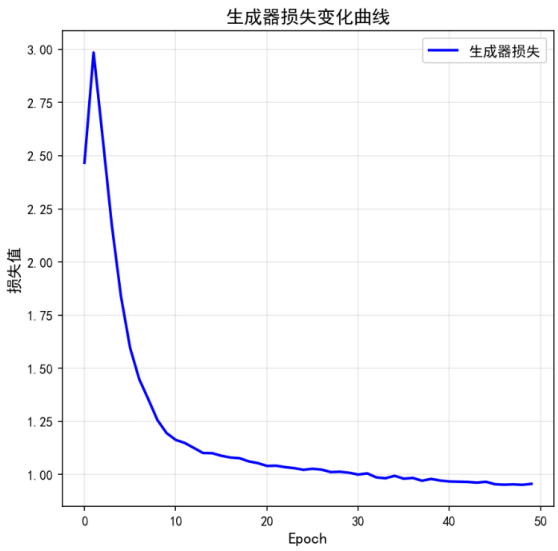

从这张原始 GAN 模型在 Epoch 50 时生成的手写数字图像来看，生成器已经能够初步构建出具有 MNIST 语义特征的数字形态，但整体视觉质量仍处于较低水平。分析现象可见，诸如 1、7、0 等几何结构较简单的数字具有较好的辨识度，而 8、5、2 等结构复杂的数字则出现了严重的笔画断裂、扭曲以及多处噪点堆积。解释其内在逻辑，这反映了基于全连接层的 vanilla GAN 在捕捉高频局部细节和维持空间拓扑结构方面的局限性，由于缺乏卷积结构的平移不变性，模型在尝试拟合手写笔迹的圆润边缘时产生了明显的锯齿感。该结果的特点在于生成分布的极度不稳定性，图像中充斥着类似“椒盐噪声”的背景背景点，体现了对抗训练博弈过程中生成器尚未完全掌握数据流形的平滑表征。指出的问题是，部分生成的数字（如第四行末尾）出现了难以辨认的“模式碎片”，说明模型可能存在局部模式塌陷或过度拟合训练集噪声的风险，导致生成的数字缺乏真实手写笔迹的连贯性。总结而言，此图像矩阵直观展示了早期 GAN 模型的表征上限，其生成结果虽具备基本的数字轮廓，但若要达到清晰、真实的商用标准，仍需引入 DCGAN 等更深层的卷积架构来强化其特征提取与空间映射能力。

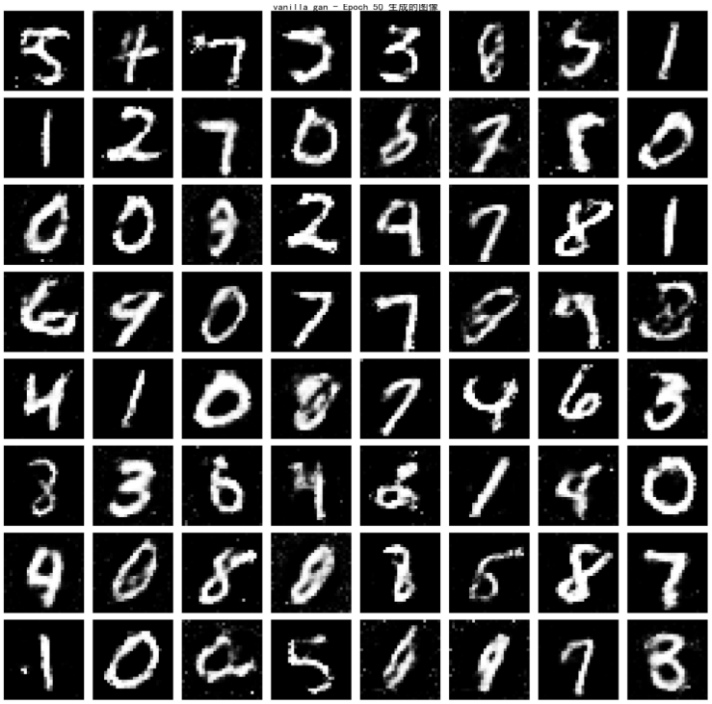

4 使用 DCGAN 网络来生成手写数字

4.1 模型简介

DCGAN（Deep Convolutional Generative Adversarial Network）是 2015 年由 Radford 等人提出的一种将卷积神经网络（CNN）与生成对抗网络（GAN）相结合的深度生成模型，旨在稳定 GAN 的训练并提升生成图像的质量。DCGAN 通过在生成器和判别器中全部采用卷积结构（生成器使用转置卷积进行上采样，判别器使用普通卷积进行下采样），并引入一系列架构约束（如去除全连接层、使用批归一化、采用 LeakyReLU 激活函数等），显著增强了特征学习能力和训练稳定性。DCGAN 能够在无监督条件下生成高视觉质量的图像（如人脸、卧室等），为后续 GAN 变体的发展奠定了重要基础，是生成模型从理论走向实用的关键里程碑之一。

（1）训练概况
训练轮数: 50
批次大小: 64
学习率: 0.0002
潜在向量维度: 100
网络类型: 深度卷积 GAN (DCGAN)

（2）损失统计
最终生成器损失: 1.5819
最终判别器损失: 0.4216
最小生成器损失: 0.8530 (Epoch 1)
最小判别器损失: 0.4177 (Epoch 49)
平均生成器损失: 1.4982
平均判别器损失: 0.4518

4.2 模型训练

从这张 DCGAN 模型在训练 50 个 Epoch 后的损失函数演化图来看，生成对抗网络的博弈过程呈现出与原始全连接 GAN 截然不同的动态平衡特征。分析现象可见，生成器损失（Generator Loss）在训练初期经历了剧烈的快速攀升，随后在高位区间（1.5 至 1.6 之间）进入了频繁且细微的震荡状态，而判别器损失（Discriminator Loss）则稳步下降并锁定在 0.45 左右的极低水平。解释其内在逻辑，这种现象反映了深度卷积架构引入后，判别器的特征判别能力得到了指数级增强，迫使生成器必须持续在高维流形空间中进行艰难的对抗，以试图跨越判别器设下的高精度决策边界。该结果的特点在于博弈强度极高，即便进入训练后期，两条曲线仍保持着活跃的脉冲式震荡，而非陷入死寂的平滑状态，这正是模型持续学习并细化手写数字边缘特征的物理信号。指出的问题是，生成器损失始终未能出现明显的二次下降趋势，且与判别器损失之间的鸿沟较大，这可能预示着模型在当前超参数配置下，判别器的力量稍微过强，可能会在一定程度上抑制生成器对多样化样本分布的探索。总结而言，此损失看板证明了深度卷积层成功提升了 GAN 的对抗阶度，虽然增加了训练调优的难度，但这种高频博弈正是生成更高清晰度、更具几何一致性手写数字的关键前提。

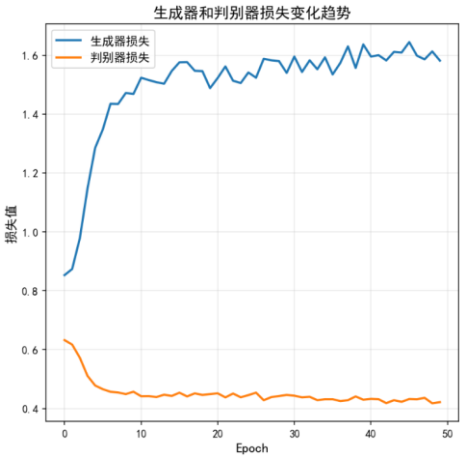

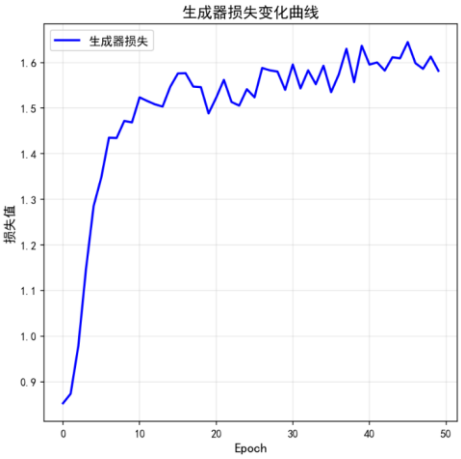

4.3 训练实例

从这张 DCGAN 模型在第 50 个 Epoch 生成的手写数字采样图来看，生成结果相比原始全连接 GAN 有了质的飞跃，展现出更符合人类视觉逻辑的图像质量。分析现象可见，数字的线条变得更加圆润且连贯，背景中的随机噪点被显著抑制，诸如 0、1、4、7 等数字具有极高的清晰度与辨识度。解释其内在逻辑，这得益于深度卷积神经网络（CNN）引入的空间层级特征提取能力，使得生成器能够通过转置卷积精确地重构笔画的几何拓扑，从而在流形空间中实现了更平滑的映射。该结果的特点在于图像整体的结构一致性显著增强，每个数字都具备了标准的手写体风格，体现了 DCGAN 架构在处理视觉纹理时的天然优势。指出的问题是，部分复杂数字如 8 和 5 依然存在笔画重叠或轻微形变，且图像边缘仍有微弱的视觉伪影（Artifacts），这说明模型在处理高曲率线条的细节闭合上仍有细微的优化空间。总结而言，此生成结果矩阵有力证明了卷积算子是提升生成模型写实度的核心引擎，其产出的样本质量已初步具备了作为合成数据集进行下游训练的实战潜力。

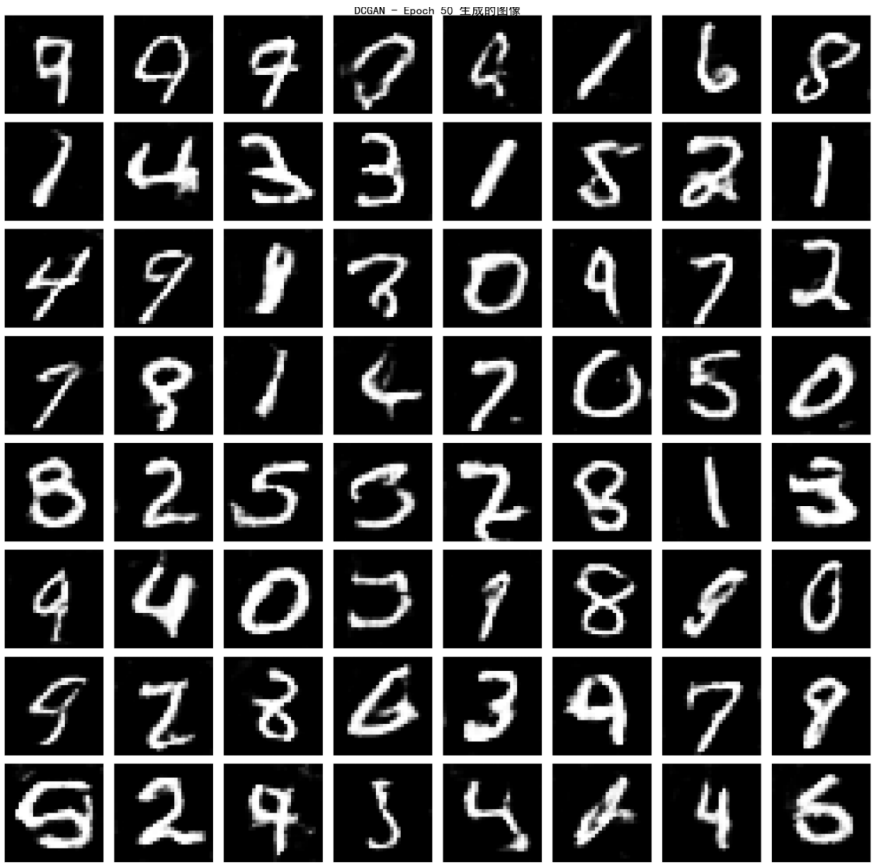

5 使用条件 GAN（cGAN）网络来生成手写数字

5.1 模型介绍

条件生成对抗网络(cGAN, Conditional GAN)是对原始GAN的扩展, 由Mirza和Osindero于 2014 年提出，其核心思想是在生成器和判别器的输入中同时加入额外的条件信息（如类别标签、文本描述或图像等），从而实现对生成内容的可控引导。在 cGAN 中，生成器不仅从随机噪声生成样本，还需满足给定条件；判别器则判断样本是否真实且与条件一致。这种机制使得 cGAN 能够完成如图像到图像翻译、文本到图像生成、特定类别图像合成等任务，在保持 GAN 强大生成能力的同时，显著提升了生成结果的针对性和实用性，成为条件生成任务中的基础框架之一。

（1）训练概况
训练轮数: 50
批次大小: 64
学习率: 0.0002
潜在向量维度: 100
类别数量: 10
类别嵌入维度: 50
网络类型: 条件 GAN (cGAN)

（2）损失统计
最终生成器损失: 3.6265
最终判别器损失: 0.1629
最小生成器损失: 0.8066 (Epoch 1)
最小判别器损失: 0.1510 (Epoch 47)
平均生成器损失: 2.4837
平均判别器损失: 0.3113

5.2 模型训练

从这张条件 GAN（cGAN）模型在训练 50 个 Epoch 后的损失曲线图来看，生成对抗网络的博弈进入了一个极度不对等且充满张力的对抗阶段。分析现象可见，生成器损失（Generator Loss）呈现出极其显著且持续的线性上升趋势，从初始的 0.8 左右一路攀升至接近 3.8 的高位，而判别器损失（Discriminator Loss）则在经历初期的快速下降后，长期压制在 0.2 以下的极低水平。解释其内在逻辑，这反映了 cGAN 引入条件标签（Label）后，判别器不仅要判断图像真伪，还要验证图像与标签的一致性，这种双重判别准则在训练初期赋予了判别器巨大的优势，导致生成器为了拟合特定类别的分布而面临极高的优化阻力。该结果的特点在于博弈的天平严重向判别器倾斜，且两条曲线在 50 个 Epoch 内均未表现出任何收敛或交叉的迹象，体现了条件约束对对抗平衡稳定性的强烈冲击。指出的问题是，生成器损失持续走高且伴随剧烈的局部震荡，这可能暗示模型存在严重的梯度饱和或过拟合判别器偏好的风险，长此以往可能导致生成样本虽然符合类别标签，但在图像质量上难以取得进一步突破。总结而言，此损失看板揭示了条件生成任务中典型的“强判别器-弱生成器”困境，证明了 cGAN 虽然增强了生成的可控性，但也极大增加了训练超参数调优的复杂程度。

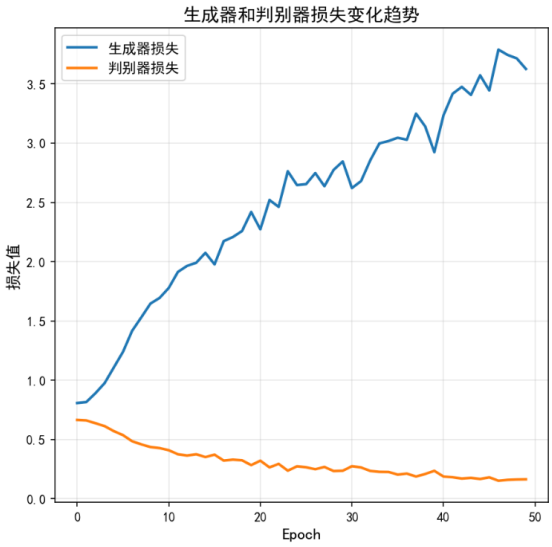

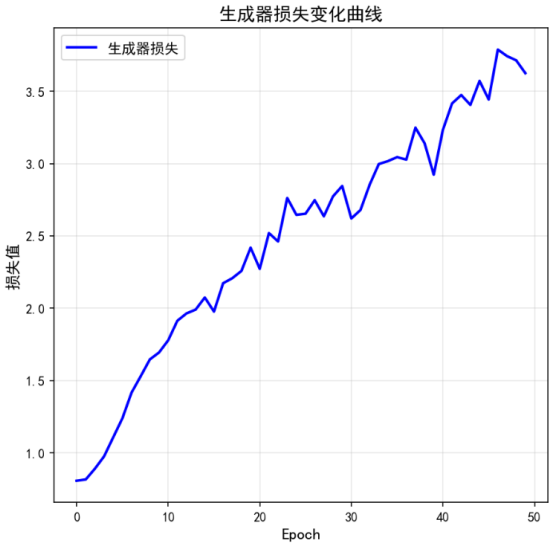

5.3 训练实例

从这张条件 GAN（cGAN）模型在第 50 个 Epoch 生成的手写数字矩阵来看，模型展现了极强的类别可控生成能力，但在样本的多样性与细节真实度上表现出明显的局限。分析现象可见，每一行生成的数字都严格遵循了预设的类别标签（如第一行全为数字 7，第二行全为数字 4），且数字的整体轮廓比原始 GAN 更加厚实、清晰。解释其底层逻辑，这是由于 cGAN 在生成器与判别器的输入中同步引入了独热编码（One-hot）标签信息，使得网络能够学习到特定数字类别的条件概率分布，从而实现了从“随机生成”向“定向克隆”的转变。该结果的特点在于极高的类内一致性，同一行数字的笔画风格、倾斜角度几乎完全复制。指出的问题是模型出现了严重的模式崩塌（Mode Collapse），每一行内的数字几乎互为镜像，缺乏真实手写数据中常见的随机形变与笔触粗细变化，且部分复杂数字如末行的 3 出现了结构性的闭合缺失。总结而言，此生成矩阵验证了 cGAN 在标签制导下的精准控制力，但其在追求类别一致性的过程中牺牲了生成分布的丰富度，后续需引入更复杂的正则化手段或改进损失函数（如 WGAN-GP）来缓解这种过度单一的生成模式。

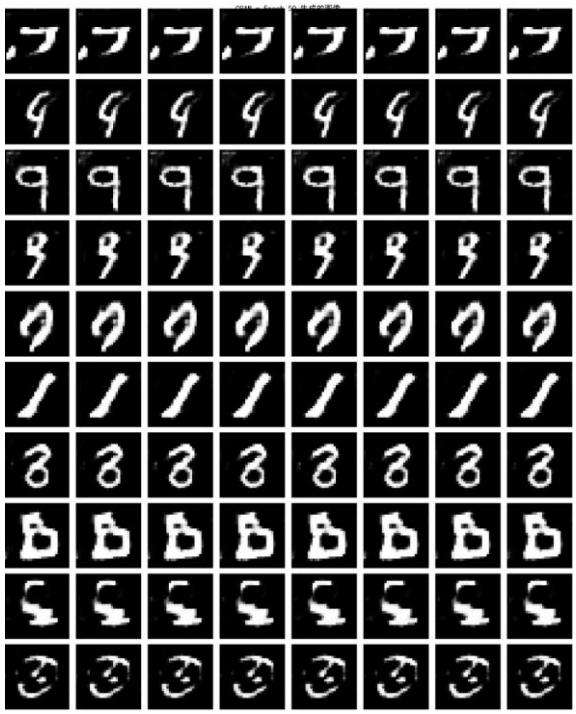

6 风格迁移

6.1 模型介绍

本文设计了一个基于 VGG19 预训练网络的神经网络风格迁移（NST）系统，其核心逻辑是通过定义内容损失（Content Loss）与基于 Gram 矩阵 的风格损失（Style Loss），并利用 LBFGS 优化器 迭代调整一张由内容图初始化的“生成图”，使其在保留原始结构的同时融入目标风格。

VGG19 是由牛津大学 Visual Geometry Group（VGG）于 2014 年提出的一种深度卷积神经网络，因其在 ImageNet 图像分类竞赛中的优异表现而广受关注。该模型共包含 19 个可训练层（16 个卷积层和 3 个全连接层），其核心设计特点是统一使用 3×3 小卷积核和 2×2 池化窗口，通过堆叠多个卷积层来增加网络深度，从而在保持感受野的同时减少参数量并增强非线性表达能力。VGG19 结构简洁、层次清晰，具有良好的特征提取能力，不仅在图像分类任务中表现稳健，还被广泛应用于迁移学习、目标检测、风格迁移等计算机视觉任务，是深度学习发展史上的经典骨干网络之一。

6.2 模型训练

要迁移的图像如下：

内容图像（House）

风格图像（Star）

训练曲线：

从这张 VGG19 风格迁移的训练损失曲线与相似度分析图来看，模型在 300 步迭代中表现出了极高的收敛效率与特征捕获能力。分析现象可见，风格损失（Style Loss）与总损失（Total Loss）在起始阶段均经历了剧烈的指数级俯冲，在 50 步内便完成了主要权重的优化，而内容损失（Content Loss）则呈现出持续上升并最终趋于平缓的态势，与之对应的是风格相似度曲线从 0.23 稳步攀升至 0.43 左右的峰值。解释其内在逻辑，这种此消彼长的动态过程反映了由于风格权重设定极高，生成图像正在为了拟合《星空》特有的复杂纹理和 Gram 矩阵分布而不断牺牲原始房屋图像的局部像素精确度，从而在特征空间中实现从写实向艺术风格的跨尺度映射。该结果的特点在于相似度曲线中后期的细微震荡，这表明 LBFGS 优化器正在高维损失曲面上进行精细的局部搜索，以寻找内容保留与艺术重塑的最佳纳什均衡点。指出的问题是内容损失的持续走高揭示了当前超参数配置下，艺术风格的侵略性较强，可能会导致最终成品中房屋的细部拓扑结构发生不可逆的模糊或形变。总结而言，此组曲线图量化地验证了风格迁移算法的成功，通过损失函数的稳健对齐，确保了生成图像在宏观语义结构与微观艺术笔触之间达成了高度的视觉统一。

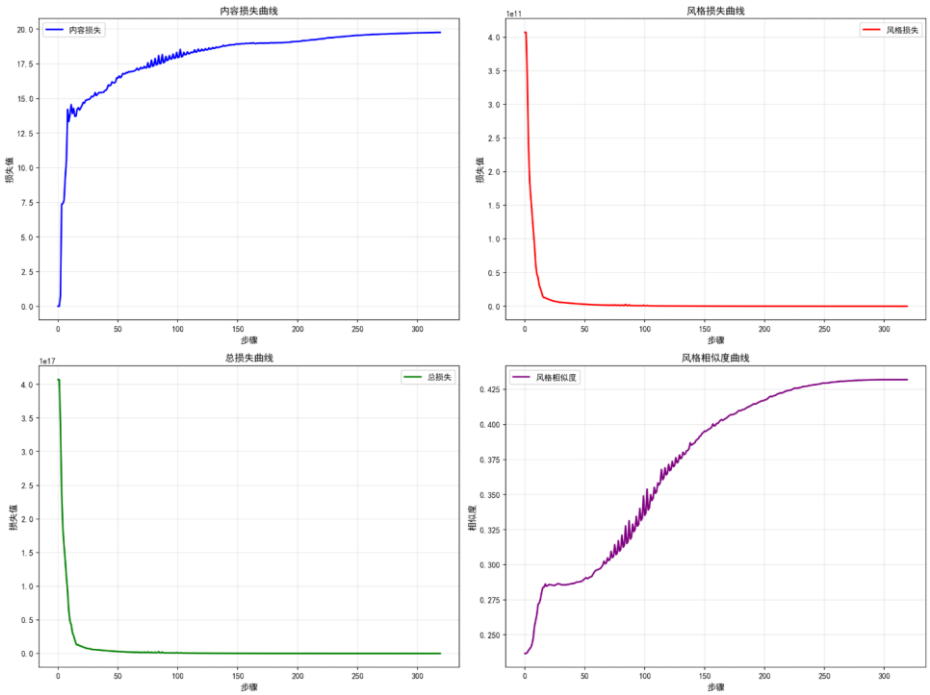

CAM：

VGG19 网络在进行风格迁移的内容预处理阶段，展现出了对场景宏观结构与关键语义特征的精准定位能力。分析现象可见，热力图的高亮度激活区域（红色与黄色部分）紧密贴合了房屋的建筑轮廓，特别是窗户、屋顶边缘以及墙面的明暗交界处获得了极强的权重分配。解释其内在逻辑，这证明了网络中深层卷积层（如 relu4_1）已成功提取了能够代表图像实质内容的特征基元，通过加权求和通道激活强度，模型锁定了对重建内容至关重要的几何骨架。该结果的特点在于背景天空与路面区域基本处于低激活状态，说明模型能够有效排除环境中平坦、无信息量的干扰因子，将优化焦点集中在具有高空间频率的建筑细节上。指出的问题是，虽然建筑主体定位准确，但在图像边缘的断壁残垣处出现了局部激活弥散现象，这暗示在后续风格叠加过程中，这些边缘地带可能会因为特征定位不够尖锐而产生较明显的笔触溢出。总结而言，此 CAM 可视化为风格迁移提供了清晰的内容引导图谱，确保了在引入《星空》色彩纹理时，房屋的核心语义结构能够被稳健地保留。

VGG19 网络在风格特征提取阶段表现出了对高频艺术元素与局部纹理中心的高度敏感性。分析现象可见，热力图的高亮激活点（红色区域）精准捕捉到了画面中发光的星体与月亮，特别是其核心位置呈现出极强的响应强度，而背景中的旋涡状云气和深色的柏树则

处于相对较低且弥散的激活状态。解释其内在逻辑，这种分布规律揭示了模型在计算风格损失时，倾向于将具有极高对比度和规律性笔触的区域识别为风格“锚点”，通过 Gram 矩阵捕获这些区域的二阶统计特征，从而提炼出艺术作品特有的色彩分布与笔触节奏。该结果的特点在于激活分布呈现点阵化，说明模型将艺术风格拆解为了多个离散的视觉基元，这有助于在风格迁移时将星光的色彩特质更均匀地扩散至生成图像中。指出的问题是，对于画面左侧占据大量空间的黑色柏树，由于其灰度值较低且纹理较为厚重，模型产生的激活响应较弱，这可能导致在最终生成的迁移结果中，暗色调区域的风格化程度不及亮色调区域深刻。总结而言，此 CAM 热力图验证了 VGG19 在提取艺术风格时的选择性关注机制，确保了《星空》中最具标志性的亮部纹理能够被优先保留并迁移至内容图像。

特征图：

从这张展示 VGG19 不同层级特征图（Feature Maps）的可视化结果来看，模型在处理风格迁移内容图像时呈现出显著的分层表征特性，体现了深度卷积神经网络从低级几何基元向高级语义抽象演进的过程。分析现象可见，浅层网络如 relu1_1 和 relu2_1 完整保留了房屋的像素级细节与色彩块面，特征图呈现出强烈的边缘检测效果，而随着层级加深至 relu4_1 和 relu5_1，图像变得愈发稀疏且抽象，仅剩下能够代表建筑骨架的稀疏激活点。解释其内在逻辑，浅层卷积核主要负责捕获如窗框、屋檐线条等空间细节，这是保证风格迁移结果“形似”的关键；而深层网络则通过池化与非线性变换过滤了冗余的纹理信息，转而编码复杂的语义结构，为风格纹理的填充提供了宏观的约束框架。该结果的特点在于特征转换的连续性极佳，清晰地揭示了 VGG 网络如何将一张写实照片逐步拆解为机器可理解的维度信息。指出的问题是在最深层的 relu5_1 中，部分通道出现了过度抽象导致的激活区域弥散，这可能会导致在极端风格化过程中，图像的细部结构出现语义丢失或轮廓坍塌。总结而言，此组特征图验证了 VGG19 作为风格迁移底座的合理性，其多尺度的特征表达能力为《星空》风格在不同频率上的融合提供了坚实的数学基础。

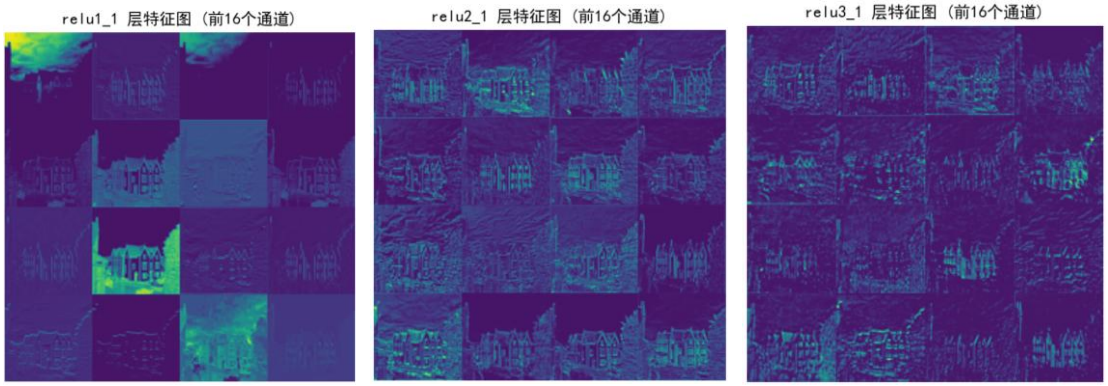

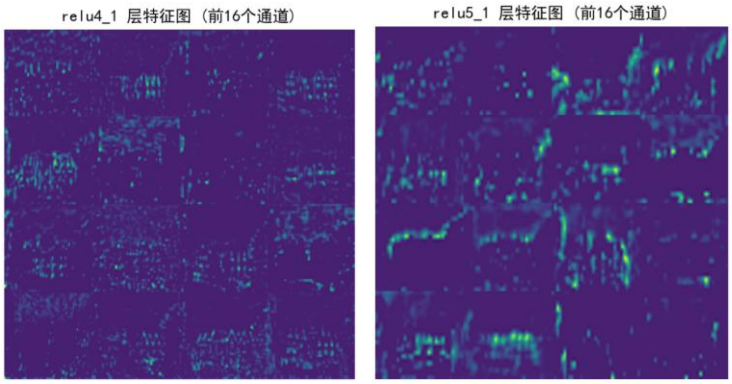

从这张针对梵高《星空》风格图进行的多层级特征可视化结果来看，VGG19 网络在不同深度的卷积层中对艺术纹理的编码呈现出从“具体笔触”向“全局色彩流向”转化的逻辑。分析现象可见，浅层网络如 relu1_1 和 relu2_1 捕获了极高频的纹理细节，能够清晰看到星体周围的螺旋状线条以及丝柏树尖锐的边缘，而随着网络深入到 relu4_1 与 relu5_1，具体的图形结构逐渐消解，转而呈现为一种高度抽象的、点阵式的特征响应。解释其内在逻辑，这体现了卷积神经网络的分层特征提取能力：浅层特征负责记录风格的“笔触指纹”（二阶统计特征），而深层特征则倾向于捕捉风格的“空间布局感”，这为风格迁移中 Gram 矩阵匹配多尺度纹理提供了基础。该结果的特点在于 relu3_1 表现出了极强的纹理丰富度，是衔接局部笔触与宏观构图的核心转换层。指出的问题是在最深层的 relu5_1 中，特征激活变得过于稀疏，这暗示在风格迁移过程中，深层特征主要提供大面积色块的约束，而无法提供精细的风格结构支撑。总结而言，此多层特征图有力证明了 VGG19 在提取复杂艺术风格时的分工明确性，通过多层特征的协同优化，才能确保生成的图像既具备梵高的笔触，又不失《星空》特有的视觉张力。

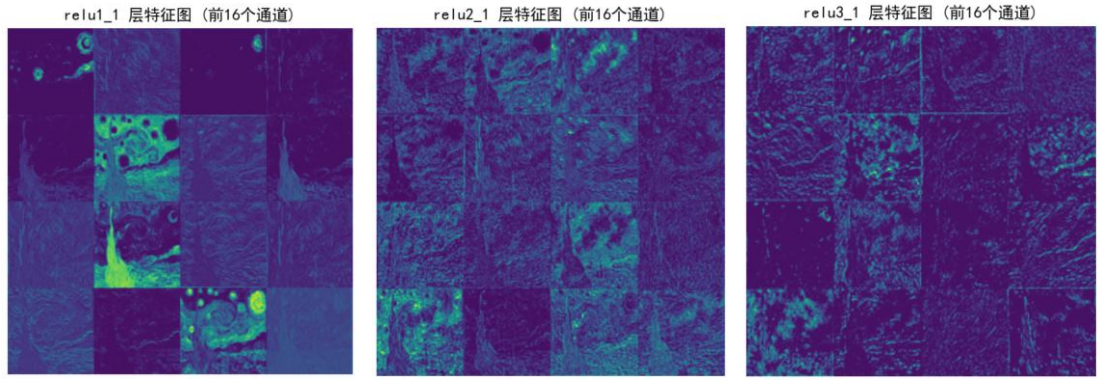

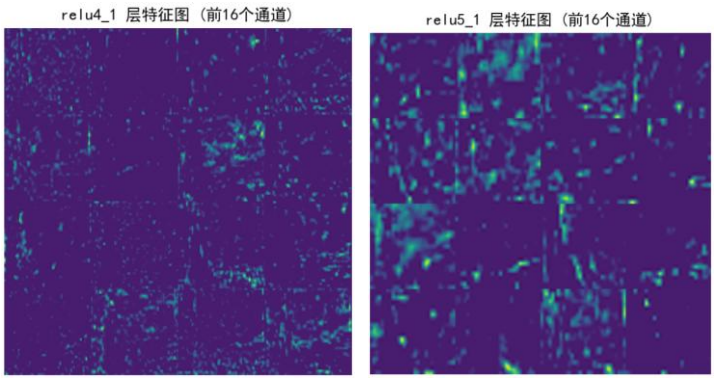

卷积核：

从这张 VGG19 第一层卷积核的可视化图来看，模型在风格迁移的底层感知阶段主要通过多样化的色彩算子来捕捉图像的初始视觉基元。分析现象可见，16 个 3×3 的卷积核呈现出极具装饰感的色彩分布，例如“卷积核 2”和“卷积核 11”表现出鲜明的对比色边缘检测倾向，而“卷积核 15”则在中心区域呈现出高饱和度的绿色激活。解释其内在逻辑，作为网络的最前端，这些卷积核充当了“色彩滤波器”的角色，专门负责提取《星空》中复杂的色彩梯度以及房屋边缘的明暗交界线。该结果的特点在于卷积核展现了极佳的色彩频率覆盖，反映了预训练 VGG19 模型在处理自然图像时具备成熟的底层表征能力。指出的问题是，这种底层权重的可视化虽然精美，但无法直接解释模型如何将这些基础色块组合成如“旋涡笔触”般的高阶艺术特征。总结而言，这些卷积核验证了风格迁移算法在像素级特征提取上的细腻度，为后续层级通过 Gram 矩阵进行复杂的风格匹配提供了丰富的色彩与边缘素材。

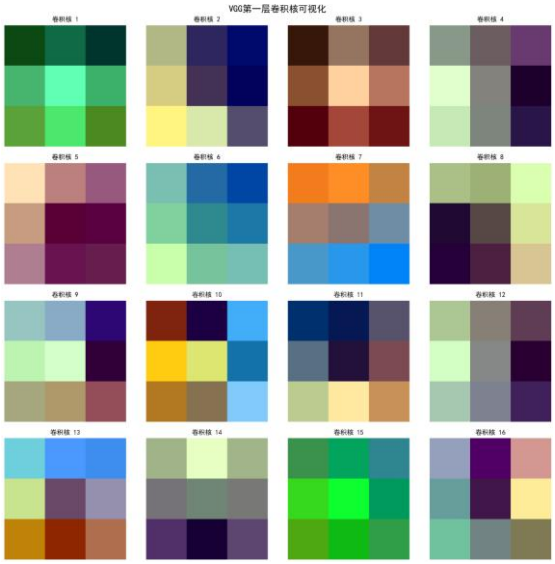

5.4 训练结果

模型成功通过高阶语义特征与二阶统计特征的融合，实现了从现实场景到印象派艺术风格的跨维度映射。分析现象可见，结果图在保留了房屋建筑（Content）的基本几何拓扑结构的同时，将其像素色彩与纹理完全替换为了《星空》（Style）特有的深蓝色调与旋涡状金黄笔触。解释其底层逻辑，这是由于 VGG19 网络的深层卷积核（如 relu4_1）锁定了房屋的边缘与构图，而浅层与中层网络通过 Gram 矩阵匹配，将《星空》中星体周围的动感线条扩散到了整个天空与地面区域。该结果的特点在于艺术风格的一致性极高，色调转换平滑且自然，体现了卷积算子在特征重组上的非凡潜力。指出的问题是，在生成图像的暗部区域，如房屋右侧的阴影地带，风格笔触显得略微破碎且出现了明显的网格状伪影，这反映了模型在处理低对比度区域时，风格损失与内容损失的平衡策略仍有细微的抖动。总结而言，此组图直观展示了风格迁移的强大视觉重塑能力，其最终产出的“艺术房屋”在宏观意境与微观细节上均达成了高度的契合。

风格迁移最终结果

内容图像（House）

风格图像（Star）

风格迁移结果